

**PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO GRANDE DO SUL
ESCOLA POLITÉCNICA
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO**

**INTELIGÊNCIA ARTIFICIAL
COMO FERRAMENTA
ESTRATÉGICA NO MERCADO
FINANCEIRO**

MATHEUS MAGRI DE OLIVEIRA

Trabalho de Conclusão II apresentado
como requisito parcial à obtenção do grau
de Bacharel em Ciência da Computação
na Pontifícia Universidade Católica do
Rio Grande do Sul.

Orientador: Prof. Eduarda Rodrigues Monteiro

DEDICATÓRIA

Dedico este trabalho à minha família, que sempre acreditou em mim mesmo nos momentos em que eu duvidei de mim mesmo. Nada do que conquistei até aqui seria possível sem o amor, o apoio, os ensinamentos e os sacrifícios que fizeram ao longo da minha vida. Esta conquista é tão deles quanto minha.

AGRADECIMENTOS

Agradeço, primeiramente, à Prof.^a Eduarda Rodrigues Monteiro, minha orientadora, pela dedicação, disponibilidade, paciência e valiosas contribuições ao longo de todo o desenvolvimento deste trabalho. Sua orientação, conhecimento e incentivo foram fundamentais para a construção desta pesquisa e para meu crescimento acadêmico e profissional.

Agradeço também aos meus colegas e amigos, que compartilharam experiências, conhecimentos e momentos importantes durante esta trajetória, tornando a caminhada mais leve e enriquecedora.

À instituição de ensino e a todos os professores que fizeram parte da minha formação, expresso minha sincera gratidão pelos ensinamentos, pela excelência acadêmica e pelas oportunidades de aprendizado proporcionadas ao longo do curso. Os conhecimentos adquiridos durante essa jornada foram essenciais para a realização deste trabalho e para minha formação como profissional.

Por fim, agradeço à minha família, pelo apoio incondicional, pela compreensão nos momentos de dificuldade e pela confiança depositada em mim. Seu incentivo constante foi um dos principais pilares que possibilitaram a conclusão desta etapa tão importante da minha vida.

INTELIGÊNCIA ARTIFICIAL COMO FERRAMENTA ESTRATÉGICA NO MERCADO FINANCEIRO

RESUMO

O mercado financeiro brasileiro enfrenta desafios estruturais significativos, caracterizados por baixos índices de inclusão econômica e alfabetização financeira. Paralelamente, o crescente volume de dados gerados diariamente pelos mercados torna cada vez mais complexa a análise de ativos e a identificação de oportunidades de investimento. Nesse cenário, técnicas de Inteligência Artificial e Aprendizado de Máquina têm se destacado como ferramentas capazes de auxiliar investidores na interpretação de padrões históricos e na projeção de tendências futuras. Este trabalho apresenta um sistema para análise e previsão de ativos financeiros, utilizando modelos híbridos baseados em Long Short-Term Memory (LSTM) e XGBoost para modelar o comportamento de ações e fornecer suporte à tomada de decisão em investimentos. O estudo contempla a análise de ativos brasileiros e internacionais, permitindo avaliar a aplicação dos modelos em diferentes contextos econômicos. A metodologia adotada envolveu a coleta e o processamento de dados históricos de mercado, o desenvolvimento e treinamento dos modelos preditivos e a avaliação de seu desempenho por meio de métricas estatísticas amplamente utilizadas na literatura. O sistema foi desenvolvido para atender investidores com diferentes níveis de experiência por meio de uma interface gráfica intuitiva, projetada para apresentar indicadores, métricas e projeções de forma clara e acessível. Dessa forma, a solução oferece informações relevantes para usuários iniciantes e análises preditivas capazes de auxiliar investidores mais experientes na análise de tendências e no acompanhamento de oportunidades de investimento. Os resultados obtidos demonstram que a integração entre modelos híbridos de Inteligência Artificial e ferramentas de visualização de dados pode contribuir para uma análise mais eficiente dos mercados financeiros, ampliando o acesso a informações estratégicas, apoiando a tomada de decisão dos investidores e contribuindo para a democratização do acesso aos investimentos e para uma maior inclusão econômica no Brasil.

Palavras-Chave: Inteligência Artificial, Mercado Financeiro, Previsão de Ativos, Carteiras de Investimento Personalizadas, Inclusão Financeira, LSTM, XGBoost.

ARTIFICIAL INTELLIGENCE AS A STRATEGIC TOOL IN THE FINANCIAL MARKET

ABSTRACT

The Brazilian financial market faces significant structural challenges, characterized by low levels of financial literacy and economic inclusion. At the same time, the increasing volume of data generated daily by financial markets has made asset analysis and the identification of investment opportunities increasingly complex. In this context, Artificial Intelligence and Machine Learning techniques have emerged as valuable tools for assisting investors in interpreting historical patterns and forecasting future trends. This work presents a system for financial asset analysis and forecasting, employing hybrid models based on Long Short-Term Memory (LSTM) and XGBoost to model stock behavior and support investment decision-making. The study includes the analysis of both Brazilian and international assets, enabling the evaluation of these models in different economic contexts. The adopted methodology involved the collection and processing of historical market data, the development and training of predictive models, and the evaluation of their performance through statistical metrics widely used in the literature. The system was developed to support investors with different levels of experience through an intuitive graphical interface designed to present indicators, performance metrics, and forecasts in a clear and accessible manner. As a result, the solution provides relevant information for novice users while offering predictive analyses capable of assisting more experienced investors in trend analysis and investment opportunity monitoring. The obtained results demonstrate that the integration of hybrid Artificial Intelligence models with data visualization tools can contribute to a more efficient analysis of financial markets, expanding access to strategic information, supporting investor decision-making, and promoting the democratization of investment opportunities and greater economic inclusion in Brazil.

Keywords: Artificial Intelligence, Financial Market, Asset Prediction / Forecasting, Personalized Investment Portfolios, Financial Inclusion, LSTM, XGBoost.

LISTA DE SIGLAS

ANBIMA – Associação Brasileira das Entidades dos Mercados Financeiro e de Capitais
API – Application Programming Interface (Interface de Programação de Aplicações)
BACEN – Banco Central do Brasil
B3 – Brasil, Bolsa, Balcão
CNN – Convolutional Neural Network (Rede Neural Convolucional)
CVM – Comissão de Valores Mobiliários
DL – Deep Learning (Aprendizado Profundo)
DRL – Deep Reinforcement Learning (Aprendizado por Reforço Profundo)
EMA – Exponential Moving Average (Média Móvel Exponencial)
ETF – Exchange Traded Fund
FEBRABAN – Federação Brasileira de Bancos
GRU – Gated Recurrent Units (Unidades Recorrentes Bloqueadas)
IA – Inteligência Artificial
LSTM – Long Short-Term Memory
MACD – Moving Average Convergence Divergence (Média Móvel Convergente/Divergente)
MAE – Mean Absolute Error (Erro Médio Absoluto)
MDP – Markov Decision Process (Processo de Decisão de Markov)
ML – Machine Learning (Aprendizado de Máquina)
NLP – Natural Language Processing (Processamento de Linguagem Natural)
OHLCV – Open, High, Low, Close, Volume
RNN – Recurrent Neural Network (Rede Neural Recorrente)
RMSE – Root Mean Squared Error (Raiz do Erro Quadrático Médio)
SVM – Support Vector Machine (Máquina de Vetores de Suporte)
XGBOOST – Extreme Gradient Boosting

SUMÁRIO

1	INTRODUÇÃO	12
1.1	OBJETIVOS	13
1.1.1	OBJETIVO GERAL	13
1.1.2	OBJETIVOS ESPECÍFICOS	13
1.2	JUSTIFICATIVA	14
1.3	METODOLOGIA	15
2	FUNDAMENTAÇÃO TEÓRICA	17
2.1	MERCADO FINANCEIRO	17
2.2	MERCADO FINANCEIRO E TECNOLOGIA	17
2.3	INTELIGÊNCIA ARTIFICIAL	18
2.4	APRENDIZADO DE MÁQUINA NO MERCADO FINANCEIRO	18
2.5	REDES NEURAIS	19
2.6	LSTM (LONG SHORT-TERM MEMORY) + XGBOOST (EXTREME GRADIENT BOOSTING)	20
2.7	VISUALIZAÇÃO DE DADOS	23
2.8	MÉTRICAS DE AVALIAÇÃO	24
3	TRABALHOS RELACIONADOS	26
3.1	TRABALHO DE CHEN ET AL. (2015)	26
3.2	TRABALHO DE FISCHER E KRAUSS (2018)	27
3.3	TRABALHO DE ZHU ET AL. (2022)	27
3.4	TRABALHO DE TIAN ET AL. (2024)	28
3.5	TRABALHO DE AMORIM (2023)	28
3.6	TRABALHO DE MATSUMOTO (2019)	29
3.7	TRABALHO DE OLIVEIRA (2023)	29
3.8	TRABALHO DE ORSSATTO (2025)	29
3.9	COMPARATIVO DOS TRABALHOS RELACIONADOS	30
3.10	CONSIDERAÇÕES FINAIS DO CAPÍTULO	32
4	IMPLEMENTAÇÃO	34
4.1	ARQUITETURA GERAL DO SISTEMA	34
4.2	TECNOLOGIAS UTILIZADAS	35

4.3	PIPELINE DE DADOS	37
4.3.1	COLETA E PROCESSAMENTO DOS DADOS	38
4.3.2	CONSTRUÇÃO DAS JANELAS TEMPORAIS	39
4.3.3	IMPLEMENTAÇÃO DA REDE LSTM	39
4.3.4	CONSTRUÇÃO DO MODELO HÍBRIDO	42
4.3.5	AValiação e persistência dos modelos	43
4.4	SISTEMA DE INFERÊNCIA E PREDIÇÕES	44
4.4.1	PIPELINE DE INFERÊNCIA	45
4.5	BACKEND E SERVIÇOS DE API	46
4.6	DESENVOLVIMENTO DA INTERFACE WEB	48
4.7	CONSIDERAÇÕES FINAIS DO CAPÍTULO	52
5	RESULTADOS E DISCUSSÃO	53
5.1	RESULTADOS DO MODELO LSTM	53
5.2	RESULTADOS DO MODELO HÍBRIDO LSTM-XGBOOST	54
5.3	COMPARAÇÃO DOS MODELOS	56
5.4	COMPARAÇÃO ENTRE ATIVOS BRASILEIROS E NORTE-AMERICANOS ...	57
5.5	DISCUSSÃO DOS RESULTADOS	58
6	CONSIDERAÇÕES FINAIS	61
	REFERÊNCIAS	63

1. INTRODUÇÃO

O mercado financeiro brasileiro enfrenta um desafio estrutural profundo, caracterizado por baixos índices de inclusão econômica e alfabetização financeira. Estudos recentes revelam que apenas 37% da população investe em ativos financeiros (B3, 2025), enquanto 55% dos brasileiros admitem possuir baixo conhecimento em educação financeira (FEBRABAN, 2025). Este cenário reforça continuamente um ciclo de subdesenvolvimento, uma vez que a carência de investimentos reduz a circulação de capital e contribui para que grande parte da população permaneça afastada do desenvolvimento econômico (RAIHER; LIMA, 2017). A complexidade deste problema é abrangente, envolvendo fatores educacionais, culturais, econômicos e institucionais. Diante disso, abordagens inovadoras e o uso de alternativas tecnológicas mostram-se ótimas ferramentas para contribuir de forma significativa no avanço da inclusão e eficiência financeira da população.

Ademais, o avanço tecnológico nas últimas décadas tem transformado a forma de lidar com os recursos financeiros; hoje, é possível coletar, processar e analisar enormes volumes de dados em tempo real, identificando padrões complexos para embasar decisões financeiras (GOV.BR, 2023). Por meio de diferentes áreas da Computação, como por exemplo, a Inteligência Artificial, inúmeras tarefas podem ser automatizadas. Para tanto, algoritmos podem executar rotinas de análise de ativos e sugerir alternativas de investimento de forma personalizada, oferecendo maior agilidade e precisão em relação a métodos convencionais. Em síntese, a incorporação da IA ao setor financeiro contribui para aprimorar as ferramentas existentes e ampliar o acesso a um público de investidores ainda inexplorado.

O presente trabalho propõe explorar o uso da Inteligência Artificial, com ênfase em algoritmos de Aprendizado de Máquina Supervisionado aplicados à análise de dados financeiros, visando contribuir para a criação de ferramentas de apoio à tomada de decisão no mercado de capitais. A proposta busca não apenas aprimorar a capacidade analítica de investidores já ativos, mas também facilitar o acesso de novos participantes ao universo dos investimentos. Para isso, a Inteligência Artificial será empregada na construção de modelos preditivos capazes de analisar o comportamento histórico de ativos financeiros e identificar tendências de mercado, fornecendo informações relevantes para diferentes perfis de investidores. Complementarmente, será desenvolvida uma interface gráfica intuitiva, projetada para apresentar indicadores, métricas e projeções de forma clara e acessível, reduzindo a complexidade frequentemente associada à análise financeira.

A metodologia adotada explora ferramentas de IA para tratar a complexidade do problema por meio de uma abordagem em duas etapas. Primeiramente, foi realizada uma revisão bibliográfica sobre os principais conceitos e aplicações de *Machine Learning* e *Data Mining* no setor financeiro. Em seguida, foram modelados e avaliados algoritmos de Aprendizado de Máquina aplicados a bases de dados históricas de ações dos mercados brasileiro e internacional. O projeto consistiu em treinar modelos preditivos capazes de identificar

padrões temporais e estimar tendências futuras dos ativos, analisando seu desempenho mediante métricas estatísticas consolidadas na literatura. Paralelamente, foi desenvolvida uma plataforma de visualização que permite ao usuário acompanhar os resultados dos modelos de forma simples e intuitiva.

Os resultados visam demonstrar como o uso da Inteligência Artificial pode contribuir significativamente para tornar a análise de investimentos mais acessível, eficiente e fundamentada em dados. A combinação entre modelos preditivos e ferramentas de visualização fornece suporte à interpretação de cenários de mercado e à identificação de oportunidades de investimento, auxiliando tanto investidores iniciantes quanto usuários mais experientes. Projeções recentes indicam que o número de investidores em ativos digitais no Brasil poderá atingir metade da população até 2030 (TRENDSCE, 2025), evidenciando o potencial de expansão do mercado e a crescente demanda por ferramentas capazes de apoiar a tomada de decisão financeira. Em síntese, a pesquisa busca evidenciar que a integração entre Inteligência Artificial e mercado financeiro pode ampliar o acesso a informações estratégicas, fortalecer a tomada de decisão e contribuir para a inclusão financeira da população brasileira.

1.1 OBJETIVOS

Esta seção apresenta os objetivos que norteiam o desenvolvimento deste trabalho, delimitando o escopo da pesquisa e as metas a serem alcançadas. A definição clara dos objetivos é fundamental para orientar as decisões metodológicas adotadas ao longo do estudo, bem como para estabelecer os critérios pelos quais os resultados obtidos serão posteriormente avaliados. Para tanto, apresenta-se inicialmente o objetivo geral, que sintetiza o propósito central da pesquisa, seguido dos objetivos específicos, que detalham as etapas necessárias à sua concretização.

1.1.1 Objetivo Geral

Desenvolver e avaliar um sistema inteligente para análise e previsão de ativos financeiros, utilizando modelos híbridos baseados em LSTM (*Long Short-Term Memory*) e XG-Boost (*Extreme Gradient Boosting*), integrado a uma plataforma web para apresentação de informações financeiras e projeções preditivas de forma acessível e intuitiva.

1.1.2 Objetivos Específicos

Para atingir o objetivo geral, definem-se os seguintes objetivos específicos:

- Realizar uma revisão bibliográfica sobre Inteligência Artificial, Aprendizado de Máquina e aplicações de modelos preditivos no mercado financeiro, com ênfase em redes neurais LSTM e algoritmos baseados em *Gradient Boosting*.
- Coletar e pré-processar dados históricos de vinte ativos financeiros, sendo dez ações brasileiras e dez ações norte-americanas do setor de tecnologia, utilizando informações disponibilizadas por fontes públicas de mercado.
- Desenvolver e treinar modelos preditivos baseados em LSTM e XGBoost para análise de séries temporais financeiras.
- Implementar uma abordagem híbrida combinando as previsões produzidas pelos modelos LSTM e XGBoost, explorando as características complementares de ambas as técnicas.
- Avaliar o desempenho dos modelos por meio de métricas consolidadas na literatura, como RMSE, MAE, MAPE, coeficiente de determinação (R^2) e acurácia direcional.
- Comparar o desempenho dos modelos em ativos pertencentes aos mercados brasileiro e internacional, analisando seu comportamento em diferentes contextos econômicos e níveis de volatilidade.
- Desenvolver uma plataforma web capaz de apresentar informações históricas dos ativos, métricas de desempenho e projeções geradas pelos modelos preditivos por meio de uma interface gráfica intuitiva.
- Integrar os modelos de Inteligência Artificial à plataforma desenvolvida, permitindo a visualização centralizada dos resultados e análises produzidas pelo sistema.
- Disponibilizar o código-fonte do projeto em repositório público, garantindo transparência metodológica, reprodutibilidade e possibilidade de evolução futura da solução proposta.

1.2 JUSTIFICATIVA

A previsão de preços de ativos financeiros por meio de técnicas de Aprendizado de Máquina constitui uma das linhas de pesquisa mais ativas na interseção entre Ciência de Dados e Economia. Embora redes neurais recorrentes do tipo LSTM tenham demonstrado capacidade expressiva na modelagem de dependências temporais em séries financeiras, a literatura aponta que modelos isolados raramente capturam a totalidade dos padrões presentes em dados de mercado, particularmente em ambientes de alta volatilidade (FISCHER; KRAUSS, 2018; ZHU et al., 2022). Abordagens híbridas que combinam redes neurais com algoritmos baseados em árvores de decisão, representam uma metodologia relativamente

recente, cujos resultados práticos ainda carecem de avaliação e pesquisa, sobretudo no contexto do mercado brasileiro.

Nesse sentido, a maior parte dos estudos disponíveis concentra-se em mercados desenvolvidos, como os norte-americanos e chineses, aplicando técnicas consolidadas a ativos de alta liquidez e baixa interferência de fatores macroeconômicos estruturais. O mercado brasileiro, operado pela B3, apresenta dinâmicas particulares — entre elas, maior sensibilidade a variações cambiais, instabilidade política e ciclos de juros mais pronunciados — que podem comprometer a generalização direta de modelos treinados exclusivamente sobre dados internacionais. A escassez de estudos comparativos que avaliem simultaneamente o desempenho de modelos preditivos em ativos brasileiros e norte-americanos representa, portanto, uma lacuna científica que este trabalho se propõe a preencher.

Do ponto de vista prático, ferramentas de análise preditiva de alta sofisticação permanecem majoritariamente restritas a investidores institucionais ou plataformas proprietárias de elevado custo. O desenvolvimento de uma solução de código aberto que integre modelos híbridos de Inteligência Artificial a uma interface acessível para visualização de previsões, métricas de desempenho e resultados de *backtesting* representa uma contribuição concreta à democratização da análise financeira — alinhada ao crescimento expressivo do número de investidores individuais no Brasil.

Por fim, a reprodutibilidade e a transparência metodológica constituem valores científicos centrais. A disponibilização pública do código-fonte e dos artefatos gerados neste trabalho viabiliza a replicação dos experimentos por outros pesquisadores e serve como base para extensões futuras, seja pela incorporação de novos ativos, variáveis externas ou arquiteturas alternativas de *ensemble*.

1.3 METODOLOGIA

Para a realização deste trabalho, foram utilizados recursos teóricos e computacionais que garantissem rigor acadêmico e reprodutibilidade dos resultados. A fundamentação teórica foi construída a partir da consulta a bases científicas consolidadas, como Google Scholar, SciELO e periódicos especializados nas áreas de Inteligência Artificial, Aprendizado de Máquina e Mercado Financeiro. Complementarmente, foram consideradas publicações de instituições financeiras e órgãos reguladores, como a B3, a Comissão de Valores Mobiliários (CVM) e o Banco Central do Brasil, de modo a sustentar conceitualmente os métodos empregados.

No âmbito prático, o estudo analisou dados históricos de vinte ativos financeiros, sendo dez ações brasileiras e dez ações norte-americanas do setor de tecnologia. Os dados foram obtidos a partir da biblioteca *yfinance*, que fornece acesso às informações disponibilizadas pelo Yahoo Finance. Para cada ativo, foram utilizadas séries temporais contendo

preços de abertura, fechamento, máxima, mínima e volume de negociação (OHLCV). O processamento e a organização dessas informações foram realizados com auxílio das bibliotecas *Pandas* e *NumPy*, garantindo consistência e padronização dos dados utilizados no treinamento dos modelos.

O desenvolvimento dos modelos preditivos foi realizado em linguagem Python, utilizando os frameworks TensorFlow/Keras para implementação da rede neural recorrente do tipo LSTM e XGBoost para o modelo baseado em *Gradient Boosting*. Adicionalmente, foram empregadas bibliotecas como *Scikit-Learn* para pré-processamento dos dados, normalização, particionamento dos conjuntos de treinamento e teste, bem como para apoio à avaliação dos modelos. Também foi investigada a utilização de uma abordagem híbrida, combinando as previsões produzidas pelas duas técnicas com o objetivo de explorar suas características complementares.

A avaliação dos modelos foi conduzida mediante métricas amplamente empregadas na literatura de previsão de séries temporais financeiras, incluindo a Raiz do Erro Quadrático Médio (RMSE), o Erro Absoluto Médio (MAE), o Erro Percentual Absoluto Médio (MAPE) e o coeficiente de determinação (R^2). Complementarmente, foi utilizada a acurácia direcional, que permite avaliar a capacidade dos modelos em prever corretamente a direção dos movimentos de alta ou baixa dos ativos analisados.

Por fim, foi desenvolvido um sistema web para apresentação dos resultados gerados pelos modelos preditivos. A plataforma disponibiliza informações históricas dos ativos, métricas de desempenho e projeções futuras em uma interface gráfica intuitiva e acessível. A proposta busca transformar resultados estatísticos e previsões produzidas pelos modelos de Inteligência Artificial em informações compreensíveis e facilmente acessíveis, aproximando técnicas avançadas de análise financeira de investidores com diferentes níveis de experiência.

Como resultados esperados, no plano teórico, pretende-se verificar a hipótese de que a arquitetura híbrida LSTM-XGBoost supera o desempenho do modelo LSTM isolado na previsão de ativos financeiros, contribuindo com evidências empíricas para a literatura de modelos de *Ensemble* aplicados a séries temporais — em especial no contexto comparativo entre os mercados brasileiro e norte-americano, ainda pouco explorado em estudos anteriores. Espera-se, sobretudo, que a etapa de correção residual promova ganhos consistentes no RMSE e R^2 . No plano prático, almeja-se entregar uma plataforma web funcional e de código aberto, capaz de traduzir as previsões e métricas produzidas pelos modelos em informações acessíveis ao investidor final, contribuindo para a democratização de ferramentas de análise preditiva e, em última instância, para a inclusão financeira no Brasil.¹

¹Em atendimento ao princípio de reprodutibilidade científica, o código-fonte completo do sistema desenvolvido, incluindo os *scripts* de coleta e processamento de dados, o treinamento dos modelos preditivos e a plataforma web, encontra-se publicamente disponível em: <https://github.com/matheusmopucrs/TCC-Pronto>.

2. FUNDAMENTAÇÃO TEÓRICA

2.1 Mercado Financeiro

O mercado financeiro pode ser definido como o conjunto de instituições, instrumentos e operações voltados para a negociação de ativos financeiros, como ações, títulos públicos e privados, moedas e derivativos. Seu principal objetivo é possibilitar a alocação eficiente de recursos na economia, conectando agentes superavitários (poupadores) e deficitários (tomadores de recursos). Para Gitman (2010), o mercado financeiro exerce função essencial ao viabilizar a mobilização de capitais e ao promover o desenvolvimento econômico, uma vez que direciona recursos para setores produtivos que necessitam de investimentos.

Além disso, a diversidade de agentes participantes — incluindo instituições financeiras, investidores individuais, empresas e órgãos reguladores — assegura a eficiência das transações e a estabilidade do ambiente financeiro. Conforme destaca a UTFPR (2025), o mercado financeiro não se limita apenas à negociação de ativos, mas também desempenha papel estratégico na sustentação da atividade econômica, ao influenciar variáveis como o nível de investimento, o consumo e a geração de empregos.

Em síntese, o mercado financeiro é mais do que um espaço de trocas comerciais: trata-se de um mecanismo estruturado e regulado que promove a circulação de recursos, possibilita o crescimento econômico e contribui para a estabilidade macroeconômica.

2.2 Mercado Financeiro e Tecnologia

O sistema financeiro tradicional, caracterizado pelo conservadorismo em seus processos, gera confiança aos seus usuários, porém sofre com falta de agilidade, competitividade e inovação. Este cenário abriu espaço para o empreendedorismo focado na junção entre tecnologia e finanças. Os empreendedores, mesmo em menor escala, passaram a focar nas necessidades dos usuários, utilizando a diversidade de investimentos disponíveis no mercado e já colhendo os frutos dessas iniciativas (DOLIVEIRA, 2017).

Nesse contexto, surgiram as Fintechs, termo que significa "tecnologia financeira" e que representa a mudança na forma como os clientes realizam pagamentos, enviam dinheiro, tomam empréstimos e investem. Em quatro palavras, Fintech significa "Poder Para o Povo!", pois uma forma de empoderar as pessoas é fornecer a elas acesso facilitado ao dinheiro (CHISHTI, 2017, p. 10).

Conforme demonstrado pelo FINTECHLAB (2017), essas empresas tecnológicas estão ampliando o acesso aos serviços financeiros, principalmente em mercados até então

pouco atendidos pelos bancos tradicionais, contribuindo para a modernização e maior eficiência do sistema financeiro nacional.

2.3 Inteligência Artificial

A Inteligência Artificial (IA) é um campo da ciência da computação que busca desenvolver sistemas capazes de simular capacidades humanas, como raciocínio, aprendizado, percepção e tomada de decisão. Seu surgimento remonta à década de 1950, quando John McCarthy cunhou o termo e pesquisadores como Alan Turing já discutiam a possibilidade de máquinas pensarem (RUSSELL; NORVIG, 2021). Desde então, a IA evoluiu de sistemas baseados em regras rígidas para modelos mais sofisticados, como Aprendizado de Máquina e redes neurais, que permitem que os sistemas se adaptem e melhorem a partir de dados.

No contexto atual, a IA tornou-se uma tecnologia transversal, aplicada em diversos setores para automatizar processos, analisar grandes volumes de dados e apoiar a tomada de decisões. No Brasil, a literatura acadêmica destaca a IA como uma inovação tecnológica capaz de gerar ganhos de eficiência e competitividade, sobretudo em áreas como saúde, educação e finanças (Machado et al., 2023; Assis; Silva, 2021). No setor financeiro, por exemplo, a IA é amplamente utilizada para identificar fraudes, avaliar riscos de crédito e oferecer serviços personalizados, mostrando-se fundamental para a modernização do sistema bancário e para a democratização do acesso a serviços financeiros (FEBRABAN; Accenture, 2024).

Assim, a Inteligência Artificial pode ser entendida tanto como um avanço histórico da ciência da computação quanto como uma ferramenta estratégica para o desenvolvimento econômico e social. Sua capacidade de aprender com dados e apoiar decisões complexas evidencia seu papel central na transformação digital em curso, consolidando-se como uma das tecnologias mais influentes do século XXI.

2.4 Aprendizado de Máquina no Mercado Financeiro

O Aprendizado de Máquina (*Machine Learning*) constitui uma das principais subáreas da Inteligência Artificial e tem como objetivo desenvolver modelos capazes de aprender padrões e relações presentes nos dados sem a necessidade de regras explicitamente programadas. Diferentemente dos sistemas tradicionais, que seguem instruções previamente definidas, algoritmos de Aprendizado de Máquina são treinados a partir de exemplos históricos, construindo modelos capazes de identificar comportamentos recorrentes e realizar previsões sobre novos dados (GÉRON, 2022).

A crescente digitalização dos mercados financeiros resultou na geração contínua de grandes volumes de informações provenientes de negociações, indicadores econômicos,

relatórios corporativos e séries históricas de preços. Nesse cenário, técnicas de Mineração de Dados (*Data Mining*) e Aprendizado de Máquina tornaram-se ferramentas fundamentais para transformar dados brutos em conhecimento útil para análise e tomada de decisão. Segundo Han, Kamber e Pei (2022), a Mineração de Dados permite descobrir padrões, correlações e tendências que dificilmente seriam identificados por métodos convencionais de análise.

Uma das principais vantagens dessas técnicas está na capacidade de processar simultaneamente milhares de variáveis e observações, identificando relações complexas que muitas vezes não são perceptíveis à análise humana. Conforme destacam Goodfellow, Bengio e Courville (2016), modelos de aprendizado conseguem capturar padrões não lineares e comportamentos dinâmicos presentes em grandes conjuntos de dados, tornando-se particularmente adequados para problemas de previsão.

No mercado financeiro, essa capacidade é especialmente relevante devido à elevada quantidade de informações produzidas diariamente e à complexidade inerente ao comportamento dos ativos. Dessa forma, o Aprendizado de Máquina fornece uma base tecnológica capaz de apoiar análises quantitativas mais robustas, permitindo a construção de sistemas preditivos voltados à identificação de tendências e ao suporte à tomada de decisão em investimentos.

2.5 Redes Neurais

As Redes Neurais Artificiais (RNAs) consolidaram-se, nas últimas décadas, como uma das técnicas mais eficazes para problemas de previsão, classificação e modelagem de padrões complexos. Inspiradas no funcionamento do cérebro humano, as RNAs são compostas por unidades interligadas (neurônios artificiais) capazes de aprender relações não lineares presentes em conjuntos de dados (Haykin, 2019). Por meio de um processo iterativo de ajuste de pesos, as redes aprendem a mapear entradas para saídas de forma eficiente, tornando-se especialmente úteis em cenários em que os dados apresentam alta variabilidade, ruído ou dinâmica temporal.

Diversos autores destacam que as redes neurais são particularmente adequadas para sistemas preditivos devido à sua capacidade de generalização e de captura de dependências complexas entre variáveis (Goodfellow; Bengio; Courville, 2016). No mercado financeiro, essa característica é ainda mais relevante, considerando que séries de preços são influenciadas por múltiplos fatores econômicos, comportamentais e aleatórios. Segundo Zhang, Patuwo e Hu (2021), as RNAs superam modelos estatísticos tradicionais, como ARIMA e regressões lineares, ao lidar melhor com não linearidades e padrões sazonais ocultos.

Em aplicações financeiras, redes neurais já demonstraram desempenho significativo na previsão de preços, identificação de tendências e suporte à tomada de decisão estra-

tégica. De acordo com Fischer e Krauss (2018), modelos neurais, especialmente os baseados em aprendizado profundo (*Deep Learning*), alcançam resultados superiores em tarefas como previsão de retornos, classificação de movimentos futuros e modelagem de risco. Assim, a aplicação de RNAs em sistemas preditivos representa um avanço importante tanto para o campo da Inteligência Artificial quanto para o setor financeiro, contribuindo para maior precisão, confiabilidade e competitividade nas análises quantitativas.

2.6 LSTM (Long Short-Term Memory) + XGBoost (Extreme Gradient Boosting)

Dentre as abordagens modernas de Aprendizado de Máquina, dois métodos têm se destacado pela eficácia em problemas de previsão: as redes Long Short-Term Memory (LSTM) e o algoritmo XGBoost. As LSTMs são uma variação avançada das Redes Neurais Recorrentes (RNNs), desenvolvidas por Hochreiter e Schmidhuber (1997), projetadas para lidar com dependências de longo prazo em séries temporais. Sua principal característica é a presença de portas de controle — *input, forget e output gates* — que atuam dinamicamente no gerenciamento seletivo das informações, permitindo ao modelo reter informações relevantes de longo prazo ou descartar dados não essenciais. Essa arquitetura interna confere às LSTMs uma capacidade singular de capturar dependências temporais em diferentes horizontes. Tal característica torna-as especialmente adequadas para modelar dados sequenciais altamente voláteis, não lineares e com correlações complexas de curto e longo prazo — presentes em domínios tão diversos quanto reconhecimento de fala, tradução automática e séries climáticas — sendo as séries financeiras, foco deste trabalho, um caso que se encaixa nestas categorias.

Antes de apresentar a formalização matemática, é útil compreender intuitivamente o papel de cada porta. Uma forma didática de visualizar uma célula LSTM é imaginar o *estado da célula* (C_t) como uma esteira que atravessa toda a sequência temporal, transportando as informações relevantes acumuladas até o instante atual. A cada novo passo de tempo, três mecanismos atuam sobre essa esteira: o *Forget Gate* examina o estado anterior e decide quais informações já não são mais relevantes e podem ser descartadas; o *Input Gate*, em conjunto com o *candidato* ($\tilde{C}_t$), avalia a nova entrada e decide quais informações devem ser adicionadas à esteira; e o *Output Gate* determina qual parte do estado atualizado deve ser exposta como saída da célula — o estado oculto h_t — e repassada ao próximo instante. A Figura 4.3 ilustra esse fluxo, destacando como as três portas interagem com o estado da célula ao longo do tempo.




Figura 2.1 – Estrutura interna de uma célula LSTM, destacando o fluxo do estado da célula e a atuação das portas Forget, Input e Output.

Adaptado de Towards Data Science (2018).

Segundo Greff et al. (2017), as LSTMs destacam-se por superar limitações das RNNs tradicionais, como o problema do desaparecimento do gradiente (*vanishing gradient*), alcançando resultados expressivos em previsão de séries temporais complexas. Em estudos aplicados ao mercado financeiro, Fischer e Krauss (2018) demonstram que redes LSTM obtêm desempenho superior em tarefas de previsão de retornos e movimentos de preços, sobretudo quando treinadas com janelas deslizantes (*Sliding Windows*) e séries multivariadas.

A dinâmica ilustrada na Figura 2.1 pode ser formalizada pelo seguinte conjunto de equações, que descrevem o funcionamento de uma célula LSTM em um instante t :

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.1)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.2)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (2.3)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (2.4)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.5)$$

$$h_t = o_t \odot \tanh(C_t) \quad (2.6)$$

onde x_t é o vetor de entrada no instante t ; h_{t-1} é o estado oculto do instante anterior; W_f , W_i , W_C e W_o são as matrizes de pesos de cada porta; b_f , b_i , b_C e b_o são os respectivos vetores de vies; $\sigma(\cdot)$ denota a função sigmoide, responsável por produzir valores entre 0 e 1 que funcionam como filtros — próximos de 0 bloqueiam a informação, próximos de 1 a deixam passar; $\tanh(\cdot)$ é a tangente hiperbólica, que normaliza os valores entre -1 e 1; e $\odot$ representa o produto elemento a elemento (Hadamard). Em correspondência direta com a Figura 2.1: a equação (2.1) corresponde ao *Forget Gate*; as equações (2.2) e (2.3) correspondem ao *Input Gate* e ao bloco *Candidato*; (2.4) é a atualização da esteira de estado C_t ; e (2.5) com (2.6) corres-

pondem ao *Output Gate* e à geração do estado oculto h_t (HOCHREITER; SCHMIDHUBER, 1997).

Complementarmente, o XGBoost (Extreme Gradient Boosting), introduzido por Chen e Guestrin (2016), é um algoritmo baseado em árvores de decisão que utiliza *boosting* por gradiente para otimizar previsões de forma eficiente e escalável. De forma intuitiva, o método pode ser entendido como uma sequência de "especialistas" (árvores de decisão fracas, ou *Weak Learners*): o primeiro especialista produz uma previsão inicial, o segundo é treinado especificamente para corrigir os erros deixados pelo primeiro, o terceiro corrige os erros remanescentes do segundo, e assim sucessivamente — combinando-se ao final em um modelo robusto. Sua popularidade decorre da alta acurácia, capacidade de lidar com dados ruidosos e desempenho superior em competições de ciência de dados. De acordo com Schwartz-Ziv e Arbel (2022), o XGBoost apresenta excelente estabilidade em cenários com grande dimensionalidade e forte presença de não linearidades.

A função objetivo minimizada pelo XGBoost em uma tarefa de regressão é definida por:

$$\mathcal{L}(\phi) = \sum_{i=1}^n l(\hat{y}_i, y_i) + \sum_{k=1}^K \Omega(f_k) \quad (2.7)$$

onde $l(\hat{y}_i, y_i)$ é uma função de perda diferenciável que quantifica a discrepância entre o valor predito $\hat{y}_i$ e o valor real y_i ; K é o número de árvores construídas (os "especialistas" sucessivos descritos anteriormente); e $\Omega(f_k)$ é o termo de regularização da k -ésima árvore, definido como:

$$\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \|w\|^2 \quad (2.8)$$

sendo T o número de folhas da árvore, w o vetor de pesos das folhas, γ a penalidade sobre a complexidade estrutural e λ o coeficiente de regularização L2. A inclusão explícita do termo Ω diferencia o XGBoost de implementações tradicionais de *Gradient Boosting*, conferindo-lhe maior resistência ao sobreajuste (*overfitting*) e melhor generalização em conjuntos de dados financeiros ruidosos (CHEN; GUESTIN, 2016).

Modelos híbridos que combinam redes LSTM e XGBoost têm recebido atenção crescente na literatura, em razão da complementaridade entre as duas arquiteturas: enquanto a LSTM captura dependências temporais e padrões sequenciais de longo prazo, o XGBoost é empregado para modelar relações não lineares residuais que o modelo neural não consegue capturar isoladamente. Estudos recentes evidenciam que *Ensembles* envolvendo aprendizado profundo e *boosting* tendem a alcançar maior precisão e menor erro preditivo em aplicações financeiras (ZHANG; AGGARWAL; QI, 2020). Neste trabalho, adota-se especificamente uma estratégia de **correção residual sequencial**: a LSTM gera uma previsão inicial $\hat{y}_{LSTM}$; os resíduos $r_t = y_t - \hat{y}_{LSTM,t}$ são então utilizados para treinar o XGBoost, que

aprende a modelar os erros sistemáticos da rede neural — de forma análoga aos "especialistas corretores" descritos anteriormente, porém aplicados sobre os erros da LSTM em vez dos erros de outra árvore; e a previsão final é obtida pela soma:

$$\hat{y}_{final} = \hat{y}_{LSTM} + \Delta_{XGB} \quad (2.9)$$

onde Δ_{XGB} representa a correção calculada pelo XGBoost. Essa abordagem difere de *Ensembles* por média simples, pois o modelo de correção é treinado explicitamente sobre os erros do modelo base, conferindo à combinação um caráter sequencial e interpretável.

2.7 Visualização de Dados

A crescente disponibilidade de informações financeiras trouxe novos desafios relacionados à interpretação e utilização eficiente dos dados. Embora modelos computacionais avançados sejam capazes de produzir previsões e análises complexas, sua utilidade prática depende diretamente da capacidade dos usuários compreenderem e interpretar os resultados gerados. Nesse contexto, a visualização de dados assume papel fundamental como mecanismo de comunicação entre sistemas analíticos e usuários finais.

De acordo com Few (2013), a visualização de dados consiste na representação gráfica de informações com o objetivo de facilitar a identificação de padrões, tendências e anomalias. Em ambientes financeiros, gráficos, indicadores e painéis interativos permitem que investidores analisem grandes volumes de dados de maneira rápida e intuitiva, reduzindo a complexidade associada à tomada de decisão.

Os Sistemas de Apoio à Decisão (*Decision Support Systems - DSS*) surgem como uma evolução desse conceito ao integrar modelos analíticos, bases de dados e mecanismos de visualização em uma única plataforma. Segundo Power (2020), esses sistemas têm como finalidade fornecer informações relevantes para apoiar decisões humanas, sem substituir completamente o julgamento do usuário.

No contexto do mercado financeiro, a combinação entre modelos preditivos e interfaces gráficas intuitivas permite transformar resultados estatísticos complexos em informações acessíveis para investidores com diferentes níveis de conhecimento. Assim, a visualização de dados não deve ser entendida apenas como um recurso estético, mas como um componente essencial para ampliar a compreensão dos cenários de mercado e potencializar a utilização prática das análises geradas pelos modelos de Inteligência Artificial.

2.8 Métricas de Avaliação

A avaliação de modelos preditivos aplicados a séries temporais financeiras requer métricas que capturem diferentes aspectos do desempenho: a magnitude do erro, sua relevância proporcional ao valor previsto, a capacidade explicativa do modelo e sua utilidade prática para a tomada de decisão. Nesta seção, apresentam-se as definições formais das cinco métricas empregadas na avaliação dos modelos LSTM e do *Ensemble* híbrido propostos neste trabalho.

O Erro Absoluto Médio (*Mean Absolute Error - MAE*) mede a magnitude média dos erros de previsão, sem considerar sua direção, sendo expresso na mesma unidade da variável original (HYNDMAN; KOEHLER, 2006):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.10)$$

em termos práticos, o MAE indica, em média, o quanto as previsões do modelo se distanciam dos valores reais, expresso na própria unidade monetária do ativo (por exemplo, R\$ ou US\$) — quanto menor o valor, mais próximas as previsões estão dos preços efetivamente observados.

A Raiz do Erro Quadrático Médio (*Root Mean Squared Error - RMSE*) penaliza com maior intensidade os erros de maior magnitude, em razão do termo quadrático, sendo particularmente sensível a *outliers* (HYNDMAN; KOEHLER, 2006; CHEN; GUESTIN, 2016):

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.11)$$

embora também expresso na unidade original da variável, o RMSE costuma ser igual ou superior ao MAE, e a diferença entre os dois é informativa: quanto maior o RMSE em relação ao MAE, mais o modelo está sujeito a erros pontuais grandes, mesmo que a maioria das previsões seja precisa.

O Erro Percentual Absoluto Médio (*Mean Absolute Percentage Error - MAPE*) expressa o erro em termos relativos ao valor real, permitindo comparações de desempenho entre ativos com escalas de preço distintas (DE MYTTENAERE et al., 2016):

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (2.12)$$

por ser expresso em percentual e não em valores monetários, o MAPE permite comparar diretamente o desempenho do modelo entre ativos de preços muito diferentes — por exemplo, uma ação de R\$ 10 e outra de R\$ 1.000 — algo que MAE e RMSE não possibilitam isoladamente, já que ambos dependem da escala de preço de cada ativo.

em todas as equações anteriores, y_i representa o valor real observado, $\hat{y}_i$ o valor previsto pelo modelo, e n o número total de observações no conjunto de teste.

O coeficiente de determinação (R^2) indica a proporção da variância dos dados observados que é explicada pelo modelo, assumindo valores tipicamente entre 0 e 1 — quanto mais próximo de 1, maior a capacidade explicativa do modelo (FISCHER; KRAUSS, 2018):

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2.13)$$

onde $\bar{y}$ corresponde à média dos valores observados no conjunto de teste.

Por fim, a Acurácia Direcional (*Directional Accuracy* - DA) avalia a capacidade do modelo em prever corretamente o sentido do movimento do preço — alta ou baixa — independentemente da magnitude do erro. Essa métrica é amplamente utilizada em estudos de previsão financeira, pois decisões de investimento frequentemente dependem mais da direção da tendência do que do valor exato previsto (FISCHER; KRAUSS, 2018):

$$DA = \frac{100\%}{n-1} \sum_{i=1}^{n-1} \mathbb{1} [\text{ sinal}(y_{i+1} - y_i) = \text{ sinal}(\hat{y}_{i+1} - \hat{y}_i)] \quad (2.14)$$

onde $\mathbb{1}[\cdot]$ é a função indicadora, que assume valor 1 quando a condição entre colchetes é verdadeira e 0 em caso contrário, e $\text{ sinal}(\cdot)$ retorna o sinal da variação entre dois instantes consecutivos.

Em conjunto, essas cinco métricas oferecem uma avaliação diversificada dos modelos. MAE, RMSE e MAPE quantificam o erro de previsão sob perspectivas complementares — absoluta, sensível a *outliers* e relativa, respectivamente —, enquanto o R^2 mede a qualidade do ajuste geral do modelo. Já a Acurácia Direcional traduz esse desempenho estatístico em um indicador de relevância prática: dois modelos com erros de magnitude semelhante podem apresentar capacidades bem distintas de identificar tendências de mercado, o que torna essa métrica essencial para avaliar a utilidade real das previsões em decisões de investimento.

3. TRABALHOS RELACIONADOS

Inúmeras abordagens para previsão de séries temporais têm sido desenvolvidas desde a consolidação dos modelos baseados em redes neurais profundas. Desde o trabalho seminal de Hochreiter e Schmidhuber (1997), as LSTMs se estabeleceram como uma das arquiteturas mais eficazes para capturar dependências temporais de longo prazo, superando limitações de métodos estatísticos clássicos, como ARIMA e regressões lineares. Estudos posteriores, como Fischer e Krauss (2018), Zhu et al. (2022) e Chen et al. (2015), demonstram consistentemente ganhos expressivos na previsão de retornos e direções de mercado quando comparados a abordagens tradicionais.

Paralelamente, diferentes pesquisas têm investigado o papel mais amplo da Inteligência Artificial no sistema financeiro, analisando desde a automação de processos até a modernização das estratégias de investimento. Trabalhos como Oliveira (2023), Matsumoto (2019) e Amorim (2023) destacam como técnicas de IA — incluindo redes LSTM, Aprendizado de Máquina e redes neurais — estão transformando a tomada de decisão no mercado brasileiro, contribuindo tanto para a melhoria da eficiência operacional quanto para avanços em modelagem preditiva.

Diante desse panorama, torna-se relevante apresentar uma análise sucinta dos principais estudos que fundamentam esta pesquisa, contemplando tanto abordagens técnicas — como modelos LSTM e métodos híbridos de previsão — quanto investigações que discutem o impacto e a adoção da Inteligência Artificial no setor financeiro. A integração desses referenciais teóricos permite consolidar a relevância e o potencial contributivo deste trabalho para o setor financeiro.

3.1 Trabalho de Chen et al. (2015)

Chen, Zhou e Jin (2015) propuseram um dos primeiros modelos baseados exclusivamente em redes LSTM para previsão de preços e retornos de ações em horizontes curtos, utilizando dados diários do mercado chinês (índice CSI 300) entre 2000 e 2013. Os autores compararam a arquitetura LSTM com modelos estatísticos tradicionais (ARIMA), regressões lineares multivariadas e redes neurais feedforward (MLP), avaliando o desempenho por meio de métricas como MSE, RMSE, MAE e acurácia direcional.

Os resultados demonstraram que a LSTM superou de forma significativa todos os *Benchmarks*, reduzindo o RMSE em até 55% em relação ao ARIMA e apresentando maior estabilidade durante períodos de alta volatilidade. Este estudo tornou-se amplamente citado na literatura por sua metodologia bem estruturada, clareza na escolha de hiperparâmetros e validação robusta em um mercado emergente caracterizado por forte não linearidade e

ruído. Sua relevância persiste como referência fundamental em pesquisas que aplicam redes recorrentes em finanças.

3.2 Trabalho de Fischer e Krauss (2018)

O trabalho de Fischer e Krauss (2018) investigou o uso de redes LSTM para previsão da direção diária do mercado de ações norte-americano, empregando dados do índice S&P 500 no período de 1992 a 2015. O desempenho das LSTMs foi comparado a quatro modelos consolidados: Random Forest (RAF), redes neurais profundas feed-forward (DNN), regressão logística (LOG) e uma *baseline* de memória histórica.

A avaliação utilizou não apenas métricas estatísticas tradicionais, como acurácia direcional, mas também retornos simulados de estratégias *Long-Short* construídas com base nas previsões. Os resultados revelaram que as LSTMs superaram consistentemente todos os modelos concorrentes, alcançando acurácia média superior a 50% e retornos anualizados significativamente maiores — mesmo após a inclusão de custos de transação. Os autores atribuem essa vantagem à capacidade das LSTMs de capturar dependências temporais complexas e não lineares presentes nos retornos, inacessíveis a métodos lineares e modelos baseados em árvores.

3.3 Trabalho de Zhu et al. (2022)

O trabalho de Zhu et al. (2022) apresentou um modelo híbrido em duas etapas que explora de forma complementar as forças da LSTM e do XGBoost. Na primeira etapa, o XGBoost atua como mecanismo de seleção automática de variáveis, identificando e hierarquizando as variáveis de maior poder preditivo a partir de um conjunto extenso de indicadores técnicos, lags e retornos. Na segunda etapa, apenas as *features* selecionadas são fornecidas à rede LSTM, que realiza a modelagem temporal e gera a previsão final de preço.

Testado em três grandes conjuntos de dados de ações chinesas (CSI 300 e ativos individuais), o modelo híbrido superou consistentemente tanto a LSTM isolada quanto o XGBoost puro, alcançando reduções de até 18% no RMSE e 22% no MAPE em relação ao melhor modelo individual. O estudo destaca que a combinação permite ao XGBoost atuar como um filtro robusto de relevância de variáveis, reduzindo ruído e dimensionalidade, enquanto a LSTM explora eficientemente as dependências temporais das *features* pré-selecionadas. Conclui-se que a arquitetura proposta apresenta elevada viabilidade prática, boa capacidade de generalização e desempenho superior em diferentes condições de mercado.

3.4 Trabalho de Tian et al. (2024)

Tian et al. (2024) propuseram um modelo híbrido LSTM-XGBoost semelhante ao de Zhu et al. (2022), porém incorporando análise de correlação de *features* e otimização bayesiana de hiperparâmetros para aprimorar a previsão de preços de ações em mercados globais. A arquitetura proposta segue uma estrutura em cascata semelhante à de Zhu et al. (2022), na qual o XGBoost realiza uma seleção inicial de variáveis de alta correlação e importância, seguida da modelagem temporal via LSTM, com os hiperparâmetros (taxa de aprendizado, tamanho da janela e número de árvores) ajustados automaticamente por meio de otimização bayesiana para maximizar a generalização. O experimento foi conduzido em múltiplos ativos internacionais, incluindo ações de tecnologia e índices voláteis, utilizando dados diários de 2015 a 2023.

Os resultados indicaram que o modelo híbrido LSTM-XGBoost superou tanto a LSTM isolada quanto o XGBoost puro, com reduções de até 25% no RMSE e 20% no MAPE, especialmente em cenários de alta volatilidade, reforçando a vantagem do enfoque híbrido perante modelos clássicos e corroborando a utilidade prática da combinação LSTM-XGBoost.

3.5 Trabalho de Amorim (2023)

Dentro do escopo de estudos brasileiros, Amorim (2023) realizou uma revisão sistemática de métodos de Inteligência Artificial aplicados à predição de movimentos de preços no mercado financeiro, com ênfase em estudos proeminentes publicados entre 2015 e 2023. O autor identifica as redes Long Short-Term Memory (LSTM) como uma das arquiteturas mais eficazes para modelagem de séries temporais financeiras, destacando sua capacidade de capturar padrões complexos e dependências de longo prazo em dados de alta volatilidade. Outros algoritmos frequentemente bem-sucedidos incluem Random Forest, Support Vector Machines e, mais recentemente, *Ensembles* baseados em Gradient Boosting, como XGBoost e LightGBM, que superam consistentemente benchmarks estatísticos tradicionais (ARIMA, GARCH) em métricas de erro (RMSE, MAPE) e acurácia direcional.

Paralelamente, Amorim ressalta as limitações críticas: dependência de grandes volumes de dados históricos de qualidade, risco de *Overfitting* em períodos de regime instável, dificuldade de interpretabilidade dos modelos profundos e desafios na generalização para mercados emergentes como o brasileiro. O autor conclui que, embora a IA represente avanço significativo para estratégias de trading e gestão de risco, seu sucesso depende da seleção cuidadosa de técnicas, pré-processamento adequado e validação rigorosa em amostras *out-of-sample*.

3.6 Trabalho de Matsumoto (2019)

Matsumoto (2019) é um dos poucos estudos brasileiros que testou a aplicação pura de redes LSTM em ativos da B3, utilizando exclusivamente preços históricos de fechamento (sem indicadores técnicos adicionais) para prever a direção do próximo preço de abertura. Com janela de 60 dias e arquitetura LSTM de duas camadas, o modelo alcançou acurácia média de até 74,5% na tarefa de classificação binária (alta/baixa), resultado expressivo para o mercado brasileiro e significativamente superior ao benchmark ARIMA (52%). Esse desempenho destaca a capacidade da LSTM de extrair, diretamente dos preços brutos, padrões temporais complexos e não lineares típicos da volatilidade da B3, mesmo em um ambiente de alta assimetria e ruído. O trabalho reforça a viabilidade de abordagens minimalistas baseadas em redes recorrentes no contexto nacional e serve como referência empírica direta para a escolha da LSTM como componente temporal do *Ensemble* híbrido aqui proposto.

3.7 Trabalho de Oliveira (2023)

Através de um viés mais teórico e institucional, o trabalho de Oliveira (2023) oferece uma análise abrangente e atual do impacto da Inteligência Artificial no ecossistema financeiro brasileiro, com ênfase na adoção institucional por bancos tradicionais, corretoras e fintechs. O autor documenta como algoritmos de *Machine Learning* e aprendizado profundo vêm sendo incorporados para automação de decisões de investimento, análise de risco em tempo real, construção dinâmica de carteiras e detecção de fraudes, destacando casos concretos de instituições que alcançaram ganhos expressivos de eficiência operacional e escalabilidade. Oliveira ressalta ainda o papel da IA na diversificação de produtos financeiros e na redução de custos de transação, fatores que têm contribuído para a expansão do mercado de capitais e para o aumento da concorrência no setor.

3.8 Trabalho de Orssatto (2025)

Orssatto (2025) conduziu um estudo abrangente sobre estratégias híbridas de aprendizado profundo para previsão de preços de ações na B3, avaliando uma extensa gama de modelos de *Machine Learning* e *Deep Learning*. Foram testados algoritmos baseados em árvores (SVM, Bagging, Random Forest, XGBoost), redes neurais feedforward (MLP) e arquiteturas avançadas de redes recorrentes (LSTM, GRU), convolucionais (CNN) e híbridas (CNN-LSTM), utilizando dados diários de 2013 a 2023 das ações mais negociadas na bolsa brasileira. Os dados foram processados em múltiplos formatos de entrada, incluindo repre-

sentações matriciais e imagens sintéticas derivadas de séries temporais, para explorar tanto padrões temporais quanto espaciais.

Os resultados revelaram que o desempenho varia conforme o cenário de mercado: modelos baseados em árvores como XGBoost destacaram-se em condições de alta volatilidade, enquanto as LSTMs e GRUs apresentaram superioridade em sequências com dependências de longo prazo. As redes híbridas CNN-LSTM emergiram como particularmente promissoras, combinando extração de características espaciais (CNN) com modelagem temporal (LSTM) e alcançando reduções de até 15% no RMSE em relação aos baselines isolados.

Este trabalho, um dos mais recentes e contextualizados ao mercado nacional, é uma referência crucial para o presente estudo, ao validar a estratégia de *Ensemble* LSTM-XGBoost.

3.9 Comparativo dos Trabalhos Relacionados

Com o objetivo de sintetizar visualmente as diferenças metodológicas entre os principais trabalhos discutidos neste capítulo e os objetivos apresentados nesta pesquisa, a Tabela 3.1 apresenta um comparativo direto considerando o mercado e os ativos avaliados, o tipo de modelo de Inteligência Artificial empregado, as métricas utilizadas na avaliação de desempenho e a existência (ou não) de uma aplicação voltada à visualização dos resultados pelo usuário final. Os trabalhos de caráter teórico-institucional — Amorim (2023) e Oliveira (2023) — não propõem modelos preditivos próprios sobre ativos específicos e, por esse motivo, não foram incluídos na comparação.

Tabela 3.1 – Comparativo entre os principais trabalhos relacionados e esta pesquisa.

Trabalho	Mercado / Ativos	Modelo de IA	Métricas de Avaliação	Aplicação / Frontend
Chen, Zhou e Jin (2015)	Mercado chinês — índice CSI 300 (2000–2013)	LSTM pura (vs. ARIMA, regressão linear, MLP)	MSE, RMSE, MAE, Acurácia Direcional	Não
Fischer e Krauss (2018)	Mercado norte-americano — S&P 500 (1992–2015)	LSTM pura (vs. Random Forest, DNN, Regressão Logística)	Acurácia Direcional, retornos <i>Long-Short</i> simulados	Não
Zhu et al. (2022)	Mercado chinês — CSI 300 e ações individuais	Híbrido XGBoost (seleção de <i>features</i>) + LSTM	RMSE, MAPE	Não
Tian et al. (2024)	Mercado internacional — ações de tecnologia e índices (2015–2023)	Híbrido LSTM-XGBoost + otimização bayesiana de hiperparâmetros	RMSE, MAPE	Não
Matsumoto (2019)	Mercado brasileiro — ações da B3	LSTM pura (classificação binária alta/baixa, janela de 60 dias)	Acurácia (classificação binária)	Não
Orssatto (2025)	Mercado brasileiro — ações mais negociadas da B3 (2013–2023)	Múltiplos: SVM, Bagging, RF, XGBoost, MLP, LSTM, GRU, CNN, CNN-LSTM	RMSE	Não
Este trabalho	Brasileiro (10 ações da B3) + norte-americano (10 ações de tecnologia)	Híbrido LSTM + XGBoost (correção residual sequencial)	MAE, RMSE, MAPE, R^2 , Acurácia Direcional	Sim — aplicação web (React + TypeScript)

A comparação evidencia três diferenças centrais entre esta pesquisa e os trabalhos analisados. Primeiramente, enquanto a maioria dos estudos avalia exclusivamente um mercado — predominantemente o chinês, norte-americano ou brasileiro —, este trabalho conduz uma avaliação comparativa simultânea entre ativos da B3 e da bolsa norte-americana, permitindo investigar a generalização do modelo híbrido em contextos econômicos distintos. Em segundo lugar, embora a estratégia de correção residual sequencial LSTM-XGBoost aproxime-se da arquitetura em cascata proposta por Zhu et al. (2022) e Tian et al. (2024), a avaliação aqui conduzida combina cinco métricas estatísticas, ampliando a análise para além do erro de previsão. Por fim, nenhum dos trabalhos relacionados disponibiliza uma aplicação voltada à apresentação dos resultados ao usuário final — diferencial que constitui uma das principais contribuições práticas desta pesquisa.

3.10 Considerações Finais do Capítulo

Os trabalhos apresentados neste capítulo demonstram a crescente relevância da Inteligência Artificial aplicada à previsão de ativos financeiros, evidenciando a evolução dos métodos utilizados para modelar séries temporais complexas e altamente voláteis. De modo geral, observa-se uma convergência da literatura em torno do uso de redes neurais recorrentes, especialmente as arquiteturas LSTM, devido à sua capacidade de capturar dependências temporais de longo prazo e modelar comportamentos não lineares presentes nos mercados financeiros.

Os estudos de Chen et al. (2015), Fischer e Krauss (2018) e Matsumoto (2019) demonstram que modelos LSTM puros são capazes de superar abordagens estatísticas tradicionais e outros algoritmos de Aprendizado de Máquina em diferentes mercados, incluindo os contextos chinês, norte-americano e brasileiro. Por outro lado, trabalhos mais recentes, como Zhu et al. (2022), Tian et al. (2024) e Orssatto (2025), indicam uma tendência de evolução para arquiteturas híbridas, nas quais modelos baseados em árvores de decisão, como o XGBoost, são utilizados em conjunto com redes neurais profundas para reduzir ruídos, selecionar variáveis relevantes e aprimorar a capacidade preditiva dos sistemas.

Além dos aspectos estritamente técnicos, os estudos de Amorim (2023) e Oliveira (2023) ampliam a discussão ao abordar o impacto da Inteligência Artificial no mercado financeiro contemporâneo, destacando tanto os benefícios associados à automação e à melhoria da tomada de decisão quanto os desafios relacionados à interpretabilidade dos modelos, à qualidade dos dados e à adaptação dessas soluções a mercados emergentes, como o brasileiro.

Embora os trabalhos analisados apresentem resultados expressivos, observa-se que a maior parte das pesquisas concentra-se em mercados específicos, avaliando exclusivamente ativos nacionais ou estrangeiros. Além disso, muitos estudos priorizam a análise do desempenho dos modelos preditivos, sem dedicar atenção equivalente à forma como os resultados são disponibilizados aos usuários finais. Na prática, mesmo modelos altamente precisos podem ter sua utilidade reduzida quando as informações produzidas não são apresentadas de maneira acessível e intuitiva para investidores e analistas.

Nesse contexto, o presente trabalho diferencia-se por combinar contribuições observadas em diferentes linhas de pesquisa. Do ponto de vista preditivo, a proposta utiliza uma abordagem híbrida baseada em LSTM e XGBoost, alinhada às tendências mais recentes identificadas na literatura. Entretanto, sua principal contribuição consiste na aplicação dessa arquitetura em um cenário comparativo que contempla simultaneamente ações do mercado brasileiro e do mercado internacional, permitindo analisar o comportamento dos modelos em contextos econômicos distintos.

Adicionalmente, este projeto não se limita à construção do modelo de previsão, mas busca aproximar a tecnologia do usuário final por meio de uma interface gráfica intuitiva e amigável. A plataforma desenvolvida tem como objetivo transformar resultados estatísticos e métricas complexas em informações claras e acessíveis, facilitando a interpretação dos dados e auxiliando investidores na tomada de decisão. Dessa forma, o trabalho contribui não apenas para o avanço da aplicação de técnicas de Inteligência Artificial em finanças, mas também para a democratização do acesso a ferramentas analíticas avançadas no contexto do mercado de capitais.

4. IMPLEMENTAÇÃO

Após a apresentação da metodologia e dos conceitos teóricos que embasam este trabalho, este capítulo descreve a implementação da solução desenvolvida. O objetivo é detalhar os componentes que compõem o sistema, as tecnologias empregadas, o fluxo de processamento dos dados e os mecanismos responsáveis pela geração e disponibilização das análises preditivas.

Ao longo deste capítulo serão apresentadas a arquitetura geral da solução, as etapas de coleta e processamento dos dados, a implementação dos modelos preditivos, o desenvolvimento dos serviços responsáveis pela disponibilização das informações e a construção da interface gráfica utilizada para interação com o usuário. Por fim, serão discutidos os principais aspectos relacionados ao funcionamento integrado do sistema e à disponibilização das previsões geradas pelos modelos.

4.1 Arquitetura Geral do Sistema

O sistema desenvolvido foi projetado para integrar técnicas de Inteligência Artificial, serviços de processamento de dados financeiros e mecanismos de visualização em uma única plataforma capaz de disponibilizar análises preditivas de maneira acessível ao usuário final. A arquitetura foi estruturada com base em uma separação clara entre as etapas de treinamento, inferência e apresentação dos resultados, permitindo que tarefas computacionalmente intensivas sejam executadas de forma independente das requisições realizadas pelos usuários.

Essa abordagem foi motivada principalmente pelo elevado custo computacional associado ao treinamento dos modelos de Aprendizado de Máquina. Enquanto a construção dos modelos exige o processamento de milhares de registros históricos para cada ativo financeiro, as consultas realizadas pelos usuários demandam respostas rápidas e atualizadas. Dessa forma, adotou-se uma arquitetura híbrida composta por um pipeline de treinamento executado *offline*, um servidor de API responsável pela disponibilização dos dados processados e uma aplicação web destinada à interação com o usuário.

A Figura 4.1 apresenta uma visão geral do fluxo de informações do sistema. Inicialmente, dados históricos são obtidos a partir da API pública do Yahoo Finance e utilizados no treinamento dos modelos LSTM e XGBoost. Durante essa etapa, também são gerados artefatos auxiliares, como escaladores, métricas de avaliação e arquivos de configuração necessários para a execução dos modelos. Todos os artefatos produzidos pelo processo de treinamento são armazenados localmente em diretórios específicos da aplicação, o que possibilita sua reutilização sem a necessidade de novo treinamento a cada execução do sistema.

Após o treinamento, os modelos e dados processados são disponibilizados ao servidor backend, responsável por realizar consultas, carregar previsões previamente calculadas e fornecer informações ao frontend mediante uma API REST. Durante a utilização da plataforma, informações de mercado são obtidas em tempo real, combinadas aos resultados armazenados e disponibilizadas ao usuário por meio da interface gráfica desenvolvida em React.

Essa separação permite que operações de treinamento sejam executadas apenas quando necessário, enquanto as etapas de consulta e visualização permanecem leves, escaláveis e capazes de responder rapidamente às requisições dos usuários. Além disso, a persistência local dos modelos e previsões reduz significativamente o tempo de resposta da aplicação, tornando viável a disponibilização de análises financeiras em tempo real sem comprometer a experiência do usuário.




Figura 4.1 – Arquitetura geral do sistema desenvolvido.

4.2 Tecnologias Utilizadas

Definida a arquitetura geral, descrevem-se a seguir os recursos e ferramentas empregados em cada uma das camadas apresentadas, do pipeline de treinamento à interface de visualização. O desenvolvimento do sistema proposto apoiou-se em recursos computacionais, bibliotecas e frameworks especializados em análise de dados, Aprendizado de Máquina e desenvolvimento web, selecionados de acordo com as exigências específicas de cada etapa do projeto.

- *Hardware de desenvolvimento*: Computador equipado com processador AMD Ryzen 5 5500, placa de vídeo NVIDIA GeForce GTX 1660 Super e 16 GB de memória RAM, utilizado para treinamento dos modelos e execução dos experimentos.
- *Linguagem de programação*: Python, utilizada para processamento dos dados, implementação dos modelos preditivos, treinamento das redes neurais e construção dos serviços de backend.
- *Coleta de dados*: Biblioteca *yfinance*, empregada para obtenção dos dados históricos dos ativos financeiros disponibilizados pelo Yahoo Finance.
- *Manipulação e processamento de dados*: Bibliotecas *Pandas* e *NumPy*, utilizadas para organização, tratamento e transformação das séries temporais financeiras.
- *Modelagem preditiva*: Framework TensorFlow / Keras para implementação e treinamento das redes neurais do tipo LSTM, e biblioteca XGBoost para construção dos modelos baseados em *Gradient Boosting*.
- *Pré-processamento e avaliação*: Biblioteca *Scikit-Learn*, utilizada para normalização dos dados, particionamento dos conjuntos de treinamento e teste, bem como cálculo das métricas de desempenho dos modelos.
- *Visualização e análise dos resultados*: Bibliotecas *Matplotlib* e *Seaborn*, empregadas na geração de gráficos, comparações visuais e análises dos resultados experimentais no backend, além da biblioteca *Recharts*, utilizada na renderização de gráficos interativos na interface web do sistema.
- *Backend da aplicação*: Framework FastAPI, utilizado para disponibilização dos serviços da aplicação, integração com os modelos preditivos e comunicação entre a plataforma web e os componentes de Inteligência Artificial.
- *Desenvolvimento da interface web*: React com TypeScript, utilizado na construção da interface gráfica da plataforma. Também são empregados Tailwind CSS para estilização, TanStack Router para navegação entre páginas, Recharts para visualização gráfica dos dados financeiros e Zod para validação dos parâmetros da aplicação.
- *Persistência e serialização dos modelos*: Bibliotecas *Joblib* e *JSON*, utilizadas para armazenamento dos modelos treinados, escaladores e resultados gerados durante o processo de treinamento.
- *Controle de versão*: Git e GitHub, utilizados para gerenciamento do código-fonte, rastreamento das alterações e controle de versões do projeto.

Os recursos apresentados foram selecionados por oferecerem suporte adequado às diferentes etapas do desenvolvimento da solução, abrangendo desde a coleta e o processamento dos dados até a construção dos modelos preditivos e da plataforma web de visualização. Embora estas tenham sido as tecnologias adotadas ao longo desta implementação, outras ferramentas com funcionalidades equivalentes poderiam ser empregadas sem comprometer os objetivos propostos pelo trabalho, desde que preservadas as características necessárias para treinamento, inferência e disponibilização dos resultados.

Ademais, todo o código-fonte desenvolvido durante este trabalho — incluindo os módulos de coleta e processamento de dados, treinamento dos modelos preditivos, implementação da abordagem híbrida LSTM-XGBoost e desenvolvimento da interface web — encontra-se disponível em um repositório público no GitHub. Essa iniciativa tem como objetivo garantir transparência metodológica e possibilitar a replicação dos experimentos por outros pesquisadores.

4.3 Pipeline de Dados

O desenvolvimento dos modelos preditivos exigiu a construção de um fluxo estruturado de processamento capaz de transformar dados históricos brutos do mercado financeiro em previsões utilizáveis pelo sistema. Para isso, foi implementado um *pipeline* composto por etapas sequenciais de coleta, preparação, treinamento, avaliação e armazenamento dos modelos, viabilizando a automatização do processo de geração das previsões.

A adoção dessa abordagem teve como principal objetivo garantir a padronização dos dados utilizados pelos modelos de Inteligência Artificial, reduzindo inconsistências e assegurando que todas as etapas do treinamento fossem executadas de forma reproduzível. Além disso, a separação do processo em etapas independentes facilita futuras atualizações dos modelos, permitindo que novos dados de mercado sejam incorporados sem a necessidade de alterações significativas na arquitetura do sistema.

O fluxo desenvolvido inicia-se com a obtenção dos dados históricos dos ativos financeiros, seguida pelo tratamento e organização das séries temporais. Posteriormente, são construídas as janelas temporais utilizadas como entrada para os algoritmos de Aprendizado de Máquina. A partir dessas informações, realiza-se o treinamento dos modelos LSTM e XGBoost, bem como a construção do modelo híbrido responsável por combinar as previsões geradas individualmente por cada abordagem.

A Figura 4.2 apresenta uma visão geral das etapas que compõem o *pipeline* de treinamento desenvolvido neste trabalho.




Figura 4.2 – Pipeline de treinamento utilizado no sistema.

4.3.1 Coleta e Processamento dos Dados

A etapa de coleta de dados constitui a base de todo o sistema desenvolvido, uma vez que a qualidade das previsões geradas pelos modelos está diretamente relacionada à qualidade e à consistência das informações utilizadas durante o treinamento. Para este trabalho, optou-se pela utilização da biblioteca *yfinance*, uma interface amplamente utilizada pela comunidade científica e por desenvolvedores para acesso aos dados disponibilizados pelo Yahoo Finance.

A escolha dessa ferramenta foi motivada por diversos fatores. Em primeiro lugar, a plataforma disponibiliza gratuitamente um amplo histórico de dados financeiros para ativos negociados em diferentes mercados internacionais, incluindo ações brasileiras listadas na B3 e empresas negociadas nas bolsas norte-americanas. Além disso, a biblioteca oferece uma interface simples de integração com aplicações em Python, o que possibilita automatizar o processo de coleta e atualização das informações de mercado sem a necessidade de contratos com provedores comerciais de dados.

O conjunto de dados utilizado é composto por vinte ativos financeiros, sendo dez ações pertencentes ao mercado brasileiro e dez ações de empresas de tecnologia negociadas no mercado norte-americano. A seleção desses ativos teve como objetivo permitir a análise do comportamento dos modelos em diferentes contextos econômicos, níveis de liquidez e características de mercado.

Para cada ativo foram coletadas séries históricas do tipo OHLCV (*Open, High, Low, Close and Volume*), amplamente utilizadas em aplicações de análise quantitativa e previsão financeira. Esses dados incluem o preço de abertura, preço máximo, preço mínimo, preço de fechamento e volume negociado em cada período analisado. Entre essas variáveis, o preço de fechamento foi utilizado como principal referência para o treinamento dos modelos preditivos, por representar o valor consolidado do ativo ao final de cada sessão de negociação.

Após a coleta, os dados passaram por uma etapa de processamento destinada a garantir sua consistência e adequação ao treinamento dos modelos. Inicialmente, foram removidos registros incompletos ou inconsistentes que poderiam comprometer o processo de aprendizado. Em seguida, os dados foram organizados cronologicamente e submetidos a procedimentos de normalização utilizando a técnica *Min-Max Scaling*, responsável por transformar os valores para uma escala padronizada entre 0 e 1.

A normalização é particularmente importante em modelos baseados em redes neurais, pois reduz discrepâncias de magnitude entre diferentes ativos e contribui para a estabilidade do processo de treinamento. Além disso, essa etapa auxilia na convergência dos algoritmos de otimização empregados pela rede LSTM, favorecendo um aprendizado mais eficiente dos padrões temporais presentes nas séries financeiras.

Em suma, ao final desse processo de coleta e tratamento, os dados encontram-se estruturados e padronizados, tornando-se aptos para a etapa seguinte de construção das janelas temporais utilizadas durante o treinamento dos modelos preditivos.

4.3.2 Construção das Janelas Temporais

Estruturados e normalizados os dados, foi necessário transformar as séries temporais em um formato adequado ao treinamento dos modelos preditivos. Para isso, adotou-se a técnica de janelas temporais deslizantes (*Sliding Windows*), amplamente utilizada em modelos de previsão de séries temporais por permitir que o modelo aprenda padrões a partir de observações históricas consecutivas.

O princípio dessa abordagem consiste em utilizar uma sequência de valores passados como entrada para prever um valor futuro. Assim, em vez de analisar observações isoladas, os modelos passam a considerar o comportamento recente do ativo como contexto para a geração das previsões. No sistema desenvolvido, foi adotada uma janela de 60 dias úteis, de modo que cada amostra de treinamento é composta pelos sessenta períodos imediatamente anteriores ao valor que se deseja prever.

Definida a estrutura das janelas, o conjunto de dados foi dividido em duas partes, sendo 80% destinado ao treinamento e 20% reservado para testes. Diferentemente de aplicações convencionais de Aprendizado de Máquina, a divisão foi realizada preservando integralmente a ordem cronológica das observações, evitando que informações futuras fossem utilizadas durante o treinamento. Essa estratégia permite reproduzir de forma mais fiel as condições encontradas em cenários reais de mercado, nos quais previsões são sempre realizadas com base exclusivamente em informações históricas disponíveis até o momento da análise.

4.3.3 Implementação da Rede LSTM

A rede Long Short-Term Memory (LSTM) foi utilizada como principal componente responsável pela modelagem temporal das séries financeiras analisadas. A escolha dessa arquitetura fundamenta-se em sua capacidade de capturar dependências de longo prazo presentes em séries temporais, característica particularmente relevante no mercado financeiro,

onde eventos passados podem influenciar o comportamento futuro dos ativos mesmo após longos intervalos de tempo.

Diferentemente das Redes Neurais Recorrentes tradicionais (RNNs), as LSTMs incorporam mecanismos internos de memória capazes de controlar o fluxo de informações ao longo da sequência temporal. Esses mecanismos são implementados a partir de portas de entrada (*Input Gate*), esquecimento (*Forget Gate*) e saída (*Output Gate*), responsáveis por seleccionar quais informações devem ser armazenadas, descartadas ou utilizadas na geração das previsões.




Figura 4.3 – Estrutura interna de uma célula LSTM e fluxo de informações entre os estados temporais.

Adaptado de Hochreiter e Schmidhuber (1997).

Conforme ilustrado na Figura 4.3, cada célula recebe simultaneamente o estado oculto proveniente do período anterior e os valores observados na etapa atual da série temporal. As três portas atuam de maneira coordenada sobre essas informações: o *Forget Gate* determina qual parcela do estado anterior deve ser descartada, o *Input Gate* seleciona quais novas informações serão incorporadas e o *Output Gate* define o estado oculto transmitido ao instante seguinte. É por meio desse controle seletivo que a arquitetura identifica quais padrões históricos permanecem relevantes para a previsão futura, mitigando problemas clássicos como o desaparecimento do gradiente (*vanishing gradient*) observado em redes recorrentes convencionais.

Na implementação desenvolvida, o modelo recebe como entrada sequências temporais compostas por janelas deslizantes de 60 pregões consecutivos. Os dados são previamente normalizados utilizando a técnica *MinMax Scaling*, permitindo que todas as variáveis sejam representadas em uma escala comum durante o treinamento.

O treinamento foi realizado utilizando o framework TensorFlow/Keras, empregando otimização baseada no algoritmo Adam (*Adaptive Moment Estimation*) e função de perda baseada no Erro Quadrático Médio (*Mean Squared Error - MSE*). Ao longo do processo, o modelo ajusta iterativamente seus parâmetros internos com o objetivo de minimizar a diferença entre os valores previstos e os preços efetivamente observados no conjunto de treinamento.

No que se refere à configuração dos hiperparâmetros, a arquitetura implementada é composta por uma camada LSTM com 64 unidades, dimensionamento que representa um ponto de equilíbrio entre a capacidade de representação do modelo e o risco de sobreajuste (*overfitting*), considerando o volume de dados disponível por ativo. À saída da camada recorrente foi aplicada uma camada de *Dropout* com taxa de 0,2, técnica de regularização que desativa aleatoriamente 20% das conexões a cada iteração de treinamento, reduzindo a tendência do modelo de memorizar ruídos característicos de séries financeiras. Na sequência, uma camada densa com 32 neurônios e função de ativação ReLU combina as representações aprendidas e adiciona não linearidade, enquanto uma camada densa final com um único neurônio projeta o resultado para o valor contínuo previsto, caracterizando a tarefa de regressão.

O ajuste do modelo foi configurado com um limite máximo de 80 épocas (*epochs*) e lotes (*batch size*) de 128 amostras, combinação que proporcionou treinamento estável e computacionalmente eficiente. Do conjunto de treinamento, os últimos 20% das amostras — preservada a ordem cronológica — foram reservados como partição de validação (*validation split* de 0,20), e o embaralhamento dos dados foi desabilitado (*shuffle = False*), uma vez que a ordenação temporal constitui o próprio sinal a ser aprendido pela rede. Complementarmente, dois *callbacks* de proteção foram empregados. O mecanismo de *EarlyStopping*, configurado com paciência de 10 épocas e restauração automática dos melhores pesos (*restore_best_weights*), interrompe o treinamento quando a perda de validação deixa de apresentar melhora, evitando o sobreajuste e reduzindo o custo computacional. Já o *ReduceLROnPlateau*, com paciência de 5 épocas, fator de redução de 0,5 e taxa mínima de 10^{-5} , reduz dinamicamente a taxa de aprendizado pela metade sempre que a perda de validação estagna, permitindo ajustes mais finos dos pesos à medida que o modelo se aproxima de um mínimo da função de perda. Em conjunto, esses mecanismos configuram um regime de treinamento autorregulado, no qual o número máximo de épocas atua apenas como teto de segurança, raramente atingido na prática.

Concluído o treinamento, a rede LSTM produz previsões iniciais para cada ativo analisado, capturando padrões temporais complexos presentes nas séries históricas. Essas previsões servem como base para a etapa subsequente do sistema, na qual o modelo XGBoost é empregado para modelar e corrigir os resíduos remanescentes, compondo posteriormente o modelo híbrido utilizado pela plataforma.

4.3.4 Construção do Modelo Híbrido

Embora a rede LSTM apresente elevada capacidade para modelar dependências temporais presentes em séries financeiras, parte das variações dos preços pode permanecer não modelada após o treinamento. Com o objetivo de reduzir esses erros remanescentes, foi adotada uma arquitetura híbrida baseada em correção residual, na qual um modelo XGBoost atua como mecanismo de refinamento das estimativas produzidas pela rede neural.

O XGBoost é um algoritmo supervisionado baseado em árvores de decisão que utiliza a técnica de *Gradient Boosting* para modelar relações complexas e não lineares presentes nos dados (CHEN; GUESTRIN, 2016). Sua principal característica consiste na construção incremental de múltiplas árvores, onde cada nova árvore busca corrigir erros observados nas etapas anteriores, tornando-o particularmente adequado para tarefas de ajuste e refinamento de previsões.

Diferentemente de abordagens tradicionais de *Ensemble*, nas quais múltiplos modelos produzem previsões independentes que posteriormente são combinadas, a estratégia utilizada neste trabalho opera de forma sequencial. Inicialmente, a rede LSTM gera as previsões da série temporal. Em seguida, os resíduos resultantes — definidos como a diferença entre os valores reais observados e os valores previstos pela rede neural — são utilizados no treinamento do XGBoost. As variáveis fornecidas ao algoritmo são derivadas das próprias previsões da LSTM, permitindo que o modelo identifique padrões recorrentes nos erros cometidos e produza correções para essas estimativas.

Conforme ilustrado na Figura 4.4, a previsão final é obtida pela soma direta entre a estimativa produzida pela rede LSTM e a correção calculada pelo XGBoost. Desse modo, o modelo híbrido combina a capacidade das redes neurais recorrentes de capturar padrões temporais de longo prazo com a eficiência dos métodos baseados em árvores na identificação e correção de erros residuais sistemáticos.




Figura 4.4 – Fluxo de construção do modelo híbrido baseado em correção residual.

4.3.5 Avaliação e Persistência dos Modelos

Concluído o treinamento, os modelos desenvolvidos foram avaliados utilizando o conjunto de teste previamente separado durante a construção das janelas temporais. Como esses dados não participaram do processo de aprendizado, sua utilização permite medir a capacidade de generalização dos modelos e estimar seu desempenho em cenários mais próximos das condições encontradas durante a utilização real da plataforma.

A avaliação foi conduzida por meio de cinco métricas complementares amplamente utilizadas em problemas de regressão e previsão de séries temporais: Erro Absoluto Médio (*Mean Absolute Error* - MAE), Raiz do Erro Quadrático Médio (*Root Mean Squared Error* - RMSE), Erro Percentual Absoluto Médio (*Mean Absolute Percentage Error* - MAPE), coeficiente de determinação (R^2) e Acurácia Direcional (*Directional Accuracy* - DA). Enquanto

as métricas de erro quantificam a diferença entre os valores previstos e observados, o coeficiente R^2 mede a capacidade explicativa do modelo. Já a Acurácia Direcional indica o percentual de períodos em que a previsão acertou corretamente a direção do movimento do preço, sendo particularmente relevante no contexto financeiro, onde identificar tendências frequentemente possui maior valor prático do que minimizar apenas o erro absoluto.

Além da análise quantitativa, os resultados obtidos foram comparados visualmente às séries reais dos ativos, permitindo verificar a aderência das previsões aos comportamentos observados nos dados históricos. Essa análise complementar possibilita identificar situações em que métricas estatísticas semelhantes podem representar desempenhos visivelmente distintos sob a perspectiva do investidor.

Validados os modelos, quatro artefatos são persistidos em armazenamento local para cada ativo analisado: os pesos da rede LSTM (`.keras`), o modelo XGBoost serializado (`.pkl`), o objeto de normalização *MinMaxScaler* (`.pkl`) e um arquivo JSON contendo as previsões geradas para o conjunto de teste juntamente com as métricas calculadas durante a avaliação.

Essa estratégia garante consistência entre as etapas de treinamento e inferência, uma vez que novos dados são processados utilizando exatamente os mesmos parâmetros de normalização empregados durante o aprendizado. A persistência local desses artefatos cumpre, ainda, um papel que vai além do simples armazenamento: ela elimina a necessidade de reprocessar todo o conjunto de dados sempre que uma nova previsão é solicitada, reduzindo de forma expressiva o tempo de resposta do sistema e tornando-o adequado à utilização em ambiente interativo. Com isso, os modelos validados durante a etapa experimental permanecem prontos para serem reutilizados, servindo de base direta para o processo de inferência descrito na seção seguinte.

4.4 Sistema de Inferência e Predições

Concluído o treinamento e armazenados os modelos preditivos, inicia-se a etapa de inferência, responsável por disponibilizar previsões atualizadas aos usuários da plataforma. Diferentemente do pipeline de treinamento — executado de forma periódica e com elevado custo computacional —, a inferência foi projetada para operar em tempo real, respondendo rapidamente às solicitações realizadas pela aplicação web.

A separação entre essas duas etapas representa uma das principais decisões arquiteturais do sistema. Enquanto o treinamento concentra-se na construção e validação dos modelos, o módulo de inferência utiliza os artefatos previamente gerados para produzir novas previsões sob demanda. Essa abordagem reduz significativamente o tempo de resposta das requisições e evita a execução de operações computacionalmente intensivas durante a navegação dos usuários.

4.4.1 Pipeline de Inferência

Ao receber uma solicitação de previsão para determinado ativo, o servidor verifica inicialmente se os modelos correspondentes já se encontram carregados em memória. Caso contrário, realiza o carregamento sob demanda dos artefatos necessários para a inferência: os pesos da rede LSTM, o modelo XGBoost serializado e o objeto *MinMaxScaler*. Após o primeiro acesso, esses componentes permanecem armazenados em cache durante todo o ciclo de execução da aplicação, eliminando a necessidade de novas leituras em disco para requisições subsequentes.

O processo de inferência opera sobre duas fontes distintas de informação. A primeira corresponde às previsões históricas geradas durante a etapa de treinamento, armazenadas em arquivos JSON específicos para cada ativo. Esses arquivos contêm as previsões realizadas sobre o conjunto de teste e as métricas de desempenho calculadas, sendo utilizados diretamente pela plataforma sem necessidade de reprocessamento. A segunda fonte é composta pelos dados mais recentes do mercado financeiro, obtidos em tempo real a partir da API do Yahoo Finance.

Para a geração de novas previsões, são recuperados os preços de fechamento dos últimos seis meses do ativo selecionado. Em seguida, os valores são normalizados utilizando o mesmo *MinMaxScaler* empregado durante o treinamento, garantindo consistência entre os dados utilizados nas etapas de treinamento e inferência. A partir desses dados é construída uma janela temporal contendo os 60 pregões mais recentes, que servirá como entrada para o modelo preditivo.

Com a janela preparada, inicia-se o processo de previsão autorregressiva. A rede LSTM gera inicialmente a estimativa para o próximo pregão e, após cada previsão, o valor produzido é incorporado à sequência de entrada enquanto o registro mais antigo é removido. Esse procedimento é repetido sucessivamente, viabilizando a construção de projeções para um horizonte de 30 dias úteis.

Para cada previsão produzida pela rede neural, é aplicado o mecanismo de correção residual baseado em XGBoost. Utilizando como entrada a previsão gerada pela LSTM e características derivadas dessa estimativa, o modelo complementar calcula um ajuste destinado a reduzir erros sistemáticos observados durante o treinamento. A previsão final é então obtida pela soma entre a estimativa produzida pela rede recorrente e a correção calculada pelo XGBoost.

Por fim, os valores previstos são convertidos novamente para a escala original dos preços e disponibilizados à aplicação juntamente com suas respectivas datas de negociação. Dessa forma, o pipeline de inferência integra dados atualizados de mercado, modelos previamente treinados e mecanismos de correção residual em um fluxo único capaz de fornecer previsões de forma rápida e consistente aos usuários da plataforma.

4.5 Backend e Serviços de API

Definido o fluxo lógico de inferência, resta descrever como o servidor organiza e disponibiliza esse processo às demais partes do sistema. A comunicação entre os modelos preditivos e a interface web é realizada por meio de uma camada de serviços desenvolvida em Python utilizando o framework FastAPI. Essa camada atua como intermediária entre o usuário e os componentes de Inteligência Artificial, sendo responsável por receber requisições HTTP, coordenar a execução dos serviços internos e disponibilizar os resultados em formato estruturado para consumo pelo frontend.

A adoção do FastAPI foi motivada principalmente pelo seu elevado desempenho, simplicidade de integração com aplicações Python e suporte nativo à construção de APIs REST. Além disso, o framework oferece validação automática de dados por meio de esquemas Pydantic, serialização de objetos e geração de documentação interativa, características que reduzem a superfície de erros e simplificam a manutenção da aplicação.

A arquitetura do backend é organizada em três serviços independentes: o *DataService*, responsável pela coleta de dados históricos e informações de mercado em tempo real a partir da biblioteca *yfinance*; o *MLService*, responsável pelo gerenciamento dos modelos preditivos e pela execução das inferências; e o *FinanceService*, responsável pela simulação da estratégia de *trading* direcional e pelo cálculo das métricas de *backtesting*. Cada serviço é instanciado uma única vez durante a inicialização do servidor e compartilhado entre as requisições mediante o mecanismo de injeção de dependências do FastAPI.

Durante a inicialização, o *MLService* realiza uma varredura no diretório de modelos para identificar quais ativos possuem artefatos de treinamento disponíveis — arquivos de rede neural, regressores e escaladores gerados previamente pelo pipeline de treinamento. Os modelos em si, no entanto, não são carregados imediatamente para a memória; o carregamento ocorre de forma postergada (*lazy loading*), apenas na primeira requisição referente a um determinado ativo. Após esse carregamento inicial, os modelos permanecem em memória e os resultados de inferência são armazenados em um cache interno, de modo que as requisições subsequentes são atendidas diretamente pelo cache, sem a necessidade de reexecutar o fluxo de inferência.

Os dados de mercado, por sua vez, são obtidos sob demanda a partir da API do *yfinance* e armazenados em um cache em memória com validade de quinze minutos. Ao receber uma solicitação de previsão, o *MLService* também busca os dados históricos recentes do ativo para alimentar a sequência de entrada dos modelos e gerar as projeções para os trinta dias úteis seguintes. Esse processo utiliza uma abordagem autorregressiva: cada valor predito torna-se entrada da iteração seguinte, permitindo a geração de horizontes de previsão sem a necessidade de dados futuros conhecidos.

Os resultados são disponibilizados por meio de quatro *endpoints* específicos. O primeiro, `GET /api/stocks`, retorna a lista de ativos disponíveis na aplicação. Já o `GET /api/stocks/{slug}` fornece o instantâneo de mercado do ativo solicitado, incluindo preço atual, variação percentual, médias móveis de vinte e cinquenta períodos, volatilidade anualizada, valorização nos últimos doze meses e o histórico de preços formatado para renderização gráfica. As saídas dos modelos, por sua vez, concentram-se no `GET /api/predictions/{slug}`, que retorna as previsões do modelo LSTM puro e do modelo híbrido LSTM-XGBoost para o período de teste, as projeções futuras e as métricas de avaliação acadêmica de ambos os modelos. Por fim, o `GET /api/backtest/{slug}` expõe os resultados da simulação de estratégia direcional, incluindo retorno acumulado, índice de Sharpe, *drawdown* máximo, fator de lucro e a curva de *equity* ao longo do período analisado.

A separação em serviços independentes contribui para a modularidade da arquitetura. Essa organização permite que os modelos preditivos, os serviços de coleta de dados e a interface gráfica evoluam de forma desacoplada, facilitando futuras manutenções, expansões funcionais e integrações com novas plataformas ou fontes de dados externas.




Figura 4.5 – Arquitetura do backend: fluxo de requisição desde o frontend até os serviços internos, com destaque para o carregamento postergado dos modelos e as camadas de cache.

4.6 Desenvolvimento da Interface Web

Embora os modelos preditivos constituam o núcleo analítico da solução proposta, a utilidade prática do sistema depende diretamente da forma como as informações são apresentadas ao usuário. Para isso, foi desenvolvida uma aplicação web com o objetivo de transformar os resultados produzidos pelos algoritmos de Inteligência Artificial em informações acessíveis, organizadas e de fácil interpretação.

A aplicação foi implementada em TypeScript utilizando a biblioteca React 19 como base para a construção de componentes visuais. O roteamento é gerenciado pelo TanStack Router, que permite a transição entre telas sem recarregamento completo da página e oferece validação tipada dos parâmetros de navegação graças à integração com a biblioteca Zod. A estilização foi realizada com Tailwind CSS, e os componentes primitivos de interface — como seletores de ativos, abas de navegação e *tooltips* — são fornecidos pela biblioteca Radix UI, que entrega a lógica de interação e acessibilidade desses elementos sem exigir implementação manual. A renderização dos gráficos financeiros é realizada pela biblioteca Recharts, utilizada em todas as visualizações de séries temporais, curvas de predição e resultados de *backtesting*, dado que o React por si só não oferece recursos nativos de construção de gráficos.

A comunicação com o backend é centralizada em uma camada de serviços, que encapsula as chamadas HTTP aos endpoints da API FastAPI e realiza a tipagem das respostas. O estado de cada tela é gerenciado localmente com os *hooks* nativos do React (`useState` e `useEffect`), sem necessidade de uma solução global de gerenciamento de estado. A seleção do ativo financeiro é propagada entre as telas pelo parâmetro de consulta `?asset={slug}`, validado pelo Zod no momento do roteamento para garantir que apenas identificadores pertencentes à lista de ativos suportados sejam aceitos. Assim, a troca de ativo em qualquer ponto da aplicação dispara automaticamente uma nova requisição ao backend com o identificador correspondente.

A aplicação é composta por três telas principais, além de um *layout* raiz responsável pela navegação lateral e pelo tratamento de erros. Cada tela consome um subconjunto específico dos *endpoints* descritos na seção anterior, traduzindo as respostas da API em elementos visuais interpretáveis pelo usuário. A primeira tela, acessível pela rota `/`, tem caráter introdutório e apresenta ao usuário os objetivos do projeto, a metodologia adotada e uma visão geral comparativa entre os modelos LSTM puro e o modelo híbrido LSTM-XGBoost.




Figura 4.6 – Página inicial da aplicação, utilizada para apresentar o projeto e contextualizar o usuário sobre a metodologia empregada.

Essa tela não realiza chamadas ao backend e serve como ponto de entrada contextual para os demais módulos da aplicação.

A segunda tela, acessível pela rota `/dados-iniciais`, é responsável por exibir as informações de mercado do ativo selecionado. Ao ser carregada, a tela realiza uma requisição ao endpoint `GET /api/stocks/{slug}`, que retorna o instantâneo de mercado do ativo — incluindo preço atual, variação percentual diária, preços de abertura, máxima, mínima e volume negociado — juntamente com os dados históricos dos últimos doze meses utilizados para a renderização do gráfico de preços.




Figura 4.7 – Tela de informações do ativo contendo preço atual, indicadores de mercado e histórico de preços.

Além do histórico bruto, o gráfico incorpora as médias móveis de vinte e cinquenta períodos calculadas pelo backend, tornando visíveis as tendências de curto e médio prazo. A tela também apresenta métricas atualizadas do ativo, como volatilidade e valorização acumulada nos últimos doze meses.




Figura 4.8 – Detalhamento das métricas históricas e indicadores financeiros usados no treinamento do ativo selecionado.

A terceira tela, acessível pela rota `/previsoes`, concentra os resultados dos modelos preditivos. Ao ser carregada, a tela realiza duas requisições em paralelo ao backend: `GET /api/predictions/{slug}`, que retorna as previsões do período de teste, as projeções para os trinta dias úteis seguintes e as métricas de avaliação acadêmica de ambos os modelos (MAE, RMSE, MAPE, R^2 e acurácia direcional); e `GET /api/backtest/{slug}`, que retorna os resultados da simulação de estratégia direcional, incluindo retorno acumulado, índice de Sharpe, *drawdown* máximo, fator de lucro e a curva de *equity* ao longo do período analisado. Os resultados dos dois modelos são apresentados em conjunto, o que possibilita a comparação direta entre o desempenho do LSTM puro e do modelo híbrido LSTM-XGBoost tanto nas previsões quanto na simulação de *trading*.




Figura 4.9 – Comparação entre as previsões produzidas pelo modelo LSTM e pelo modelo híbrido LSTM-XGBoost.




Figura 4.10 – Agregado de informações relevantes sobre o ativo

4.7 Considerações Finais do Capítulo

Este capítulo percorreu as camadas que compõem a solução implementada: o pipeline de coleta e preparação dos dados, a construção e integração dos modelos LSTM e XGBoost no modelo híbrido proposto, a camada de serviços responsável por expor os resultados via API e a interface web que os torna acessíveis ao usuário final. A separação clara entre essas responsabilidades — treinamento, inferência, comunicação e apresentação — permitiu que cada componente evoluísse de forma independente e que o sistema como um todo mantivesse coerência estrutural.

O resultado dessa integração é uma plataforma que conecta a complexidade dos algoritmos de Aprendizado de Máquina a uma experiência de uso direta, na qual o usuário acessa previsões, métricas de desempenho e resultados de *backtesting* sem precisar interagir com os modelos subjacentes. Essa camada de abstração é o que torna o sistema avaliável não apenas do ponto de vista técnico, mas também do ponto de vista de sua utilidade prática. O capítulo seguinte apresenta os resultados obtidos durante essa avaliação, analisando o desempenho dos modelos sobre os ativos selecionados e discutindo os limites e as contribuições da abordagem híbrida proposta.

5. RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute os resultados obtidos pela avaliação dos dois modelos preditivos implementados: o modelo LSTM isolado e o modelo híbrido LSTM-XGBoost. A avaliação abrangeu vinte ativos financeiros — dez pertencentes ao mercado norte-americano e dez ao mercado brasileiro — sobre o conjunto de teste constituído pelos dados históricos não utilizados no treinamento, preservada integralmente a ordem cronológica das observações. As métricas analisadas foram o Erro Médio Absoluto (MAE), a Raiz do Erro Quadrático Médio (RMSE), o Erro Percentual Absoluto Médio (MAPE), o coeficiente de determinação (R^2) e a Acurácia Direcional (DA), que mede a porcentagem de movimentos de preço cujo sentido (alta ou baixa) foi corretamente previsto pelo modelo. Enquanto as quatro primeiras métricas avaliam a capacidade do modelo de reproduzir a *magnitude* dos preços, a última avalia sua utilidade para antecipar a *direção* do próximo movimento — distinção que, como será demonstrado, revelou-se central para a interpretação dos resultados.

5.1 Resultados do Modelo LSTM

O modelo LSTM puro, treinado individualmente para cada ativo, demonstrou boa capacidade de ajuste ao nível e à tendência geral das séries de preços na maior parte da amostra, porém com limitações expressivas quanto à previsão da direção dos movimentos. Esse contraste — bom ajuste de magnitude, fraco poder direcional — constitui o fio condutor da análise apresentada ao longo deste capítulo.

Em relação às métricas de ajuste, os resultados foram satisfatórios para a maioria dos ativos: dezesseis dos vinte papéis avaliados apresentaram R^2 igual ou superior a 0,90, e o MAPE permaneceu abaixo de 4% em quinze deles, indicando que a rede acompanha adequadamente o comportamento das séries em condições regulares de mercado. Os desvios em relação a esse padrão, contudo, são informativos. A NVDA (Nvidia) configurou um *outlier* severo, com MAPE de 44,63% e R^2 de $-1,974$ — valor negativo que indica desempenho inferior ao de um preditor trivial que retornasse a média do período de teste. No mercado brasileiro, a PETR4 (Petrobras) e a MGLU3 (Magazine Luiza) também apresentaram ajuste degradado, com R^2 de 0,547 e 0,772 e MAPE de 8,27% e 18,31%, respectivamente — reflexo da elevada volatilidade e das mudanças de regime de preço observadas nesses ativos ao longo da janela analisada. As possíveis causas desses casos extremos, em especial o da NVDA, são examinadas em profundidade na Seção 5.5.

A métrica mais reveladora das limitações do LSTM puro, no entanto, é a Acurácia Direcional. Considerando os vinte ativos, o modelo apresentou DA média de 51,0% (51,3% no mercado norte-americano e 50,6% no brasileiro), com valores individuais variando entre 45,8% (EQTL3) e 54,2% (MSFT) — intervalo estatisticamente próximo de uma classificação

aleatória (50%), o que equivale, na prática, a uma estratégia de *coin flip* para a decisão de compra ou venda. Em outras palavras, ainda que o LSTM reconstrua bem o *nível* das séries, ele não aprende de forma confiável os padrões de reversão e continuidade que determinam a *direção* do próximo movimento.

Esses resultados alinham-se a observações recorrentes na literatura sobre modelos autorregressivos aplicados a séries financeiras: redes LSTM tendem a produzir previsões próximas ao valor imediatamente anterior, capturando a suavidade da tendência mas falhando na detecção dos movimentos de curto prazo [11]. A Tabela 5.1 sumariza as métricas do modelo LSTM para todos os ativos avaliados.

Tabela 5.1 – Métricas de desempenho do modelo LSTM por ativo.

Ativo	MAE	RMSE	MAPE (%)	R^2	DA (%)
AAPL	5,42	7,09	2,41	0,960	53,2
AMZN	5,12	6,78	2,49	0,950	50,3
GOOGL	6,11	9,12	2,68	0,985	51,1
META	17,84	23,61	3,12	0,956	51,8
MSFT	10,24	12,77	2,38	0,920	54,2
NFLX	3,00	4,10	3,28	0,970	53,2
NVDA	69,22	80,34	44,63	-1,974	51,4
TSLA	16,26	22,16	5,35	0,946	47,9
ADBE	11,31	15,76	2,78	0,981	50,5
INTC	2,18	4,10	5,12	0,972	49,4
ABEV3	0,22	0,31	1,74	0,969	47,0
BBAS3	0,49	0,66	2,09	0,909	50,8
BBDC4	0,33	0,45	2,31	0,980	51,6
EQTL3	0,70	0,94	2,04	0,956	45,8
ITUB4	1,21	1,66	3,53	0,944	53,1
MGLU3	1,66	1,85	18,31	0,772	52,0
PETR4	2,82	3,58	8,27	0,547	51,6
SUZB3	1,03	1,42	1,99	0,909	53,1
VALE3	1,27	1,72	2,09	0,980	48,9
WEGE3	1,20	1,58	2,74	0,947	52,5

5.2 Resultados do Modelo Híbrido LSTM-XGBoost

A incorporação do XGBoost como segundo estágio do sistema — responsável por aprender os resíduos produzidos pelo LSTM e incorporá-los à previsão final — produziu efeitos claramente distintos sobre as duas dimensões avaliadas: houve ganho consistente

e generalizado nas métricas de magnitude, porém sem melhora correspondente na capacidade de previsão direcional.

No que se refere ao erro de magnitude, o modelo híbrido superou o LSTM isolado em **todos os vinte ativos** e em todas as quatro métricas de ajuste (MAE, RMSE, MAPE e R^2), com redução relativa média de aproximadamente 25% no MAPE e de 22% no RMSE. Os maiores ganhos concentraram-se justamente nos ativos de comportamento mais irregular: na TSLA, o MAPE recuou de 5,35% para 3,49% (redução de 35%); na PETR4, de 8,27% para 5,75%, com o R^2 subindo de 0,547 para 0,708; e na MGLU3, o pior MAPE da amostra caiu de 18,31% para 13,20%, acompanhado de elevação do R^2 de 0,772 para 0,885. Mesmo em ativos já bem ajustados pelo LSTM, como AAPL e META, a correção residual reduziu o erro percentual em cerca de um terço. A única exceção parcial foi a NVDA: embora o híbrido também a tenha melhorado em todas as métricas, o ganho foi marginal (MAPE de 44,63% para 43,20%; R^2 de $-1,974$ para $-1,885$), permanecendo o ajuste em patamar inaceitável — indício de que o problema desse ativo não decorre de erros residuais corrigíveis, mas de uma limitação estrutural discutida na Seção 5.5.

A Acurácia Direcional média do modelo híbrido foi de 50,1% (50,4% no mercado norte-americano e 49,8% no brasileiro), valor ligeiramente *inferior* ao do LSTM isolado (51,0%), com variação média de $-0,9$ ponto percentual por ativo. O LSTM puro registrou DA superior em treze dos vinte ativos; o híbrido prevaleceu em apenas sete, e em quatro deles (ABEV3, BBAS3, GOOGL e INTC) por diferenças marginais, inferiores a 0,5 ponto percentual. Os únicos ganhos direcionais relevantes ocorreram em EQTL3 (+4,0 p.p.), ADBE (+3,3 p.p.) e TSLA (+2,1 p.p.). Em ambos os modelos, portanto, a DA permaneceu confinada à faixa de 45% a 55% — estatisticamente indistinguível do acaso —, revelando que a correção residual aprimora a reprodução da magnitude dos preços sem transferir esse ganho para o acerto de direção. As implicações desse achado são aprofundadas na discussão. A Tabela 5.2 apresenta os resultados completos do modelo híbrido.

Tabela 5.2 – Métricas de desempenho do modelo híbrido LSTM-XGBoost por ativo.

Ativo	MAE	RMSE	MAPE (%)	R^2	DA (%)
AAPL	3,68	5,09	1,62	0,979	50,2
AMZN	3,93	5,19	1,90	0,971	49,7
GOOGL	4,88	7,81	2,04	0,989	51,5
META	13,05	17,99	2,26	0,974	50,8
MSFT	8,05	10,14	1,85	0,950	48,9
NFLX	2,92	3,98	3,16	0,972	49,7
NVDA	67,65	79,12	43,20	-1,885	49,7
TSLA	10,94	14,91	3,49	0,976	50,0
ADBE	7,58	10,95	1,88	0,991	53,8
INTC	1,82	3,72	4,02	0,977	49,5
ABEV3	0,18	0,26	1,40	0,978	47,5
BBAS3	0,36	0,48	1,52	0,953	51,1
BBDC4	0,25	0,34	1,74	0,988	50,5
EQTL3	0,49	0,67	1,42	0,978	49,8
ITUB4	0,95	1,41	2,72	0,960	49,5
MGLU3	1,14	1,31	13,20	0,885	49,5
PETR4	2,02	2,88	5,75	0,708	50,2
SUZB3	0,71	1,05	1,39	0,950	51,1
VALE3	0,84	1,14	1,41	0,991	48,6
WEGE3	0,90	1,19	2,02	0,970	50,1

5.3 Comparação dos Modelos

A comparação direta entre os dois modelos evidencia uma dissociação clara entre as duas dimensões de desempenho avaliadas. A Tabela 5.3 sumariza as métricas médias por mercado, permitindo dimensionar objetivamente esse contraste.

Tabela 5.3 – Comparação das métricas médias por modelo e mercado. Valores entre parênteses excluem a NVDA, *outlier* que distorce as médias do mercado norte-americano.

Mercado	Modelo	MAPE (%)	R^2	DA (%)
Norte-americano	LSTM	7,42 (3,29)	0,667 (0,960)	51,3
	LSTM-XGBoost	6,54 (2,47)	0,689 (0,975)	50,4
Brasileiro	LSTM	4,51	0,891	50,6
	LSTM-XGBoost	3,26	0,936	49,8

Na dimensão de magnitude, a superioridade do modelo híbrido é inequívoca: vitória em vinte de vinte ativos, em todas as métricas de erro e de ajuste, com reduções relativas

de erro percentual entre 4% (NFLX) e 35% (TSLA). Esse resultado confirma que o XGBoost, treinado sobre os resíduos da rede neural, é eficaz em identificar e corrigir padrões sistemáticos de erro de nível, sobretudo em ativos voláteis e de comportamento irregular, nos quais o LSTM mais erra.

Na dimensão direcional, entretanto, o quadro se inverte. A Tabela 5.4 detalha a Acurácia Direcional dos dois modelos para cada ativo, evidenciando que o segundo estágio de correção não apenas deixou de ampliar o acerto de direção como, em média, o reduziu ligeiramente. Nenhum dos dois modelos ultrapassou 54,2% de DA em qualquer ativo, e ambos operaram, no agregado, em torno do patamar aleatório de 50%.

Tabela 5.4 – Acurácia Direcional (%) por ativo: LSTM puro *versus* modelo híbrido.

Ativo	LSTM	Híbrido	Δ (p.p.)	Ativo	LSTM	Híbrido	Δ (p.p.)
AAPL	53,2	50,2	−3,0	ABEV3	47,0	47,5	+0,5
AMZN	50,3	49,7	−0,6	BBAS3	50,8	51,1	+0,3
GOOGL	51,1	51,5	+0,4	BBDC4	51,6	50,5	−1,1
META	51,8	50,8	−1,0	EQTL3	45,8	49,8	+4,0
MSFT	54,2	48,9	−5,3	ITUB4	53,1	49,5	−3,6
NFLX	53,2	49,7	−3,5	MGLU3	52,0	49,5	−2,5
NVDA	51,4	49,7	−1,7	PETR4	51,6	50,2	−1,4
TSLA	47,9	50,0	+2,1	SUZB3	53,1	51,1	−2,0
ADBE	50,5	53,8	+3,3	VALE3	48,9	48,6	−0,3
INTC	49,4	49,5	+0,1	WEGE3	52,5	50,1	−2,4

Em síntese, os dados demonstram que otimizar o erro de magnitude não implica melhorar o acerto de direção. Como o segundo estágio do modelo híbrido é treinado para minimizar os resíduos de preço — um objetivo da mesma natureza da função de perda quadrática utilizada pelo LSTM —, a correção aproxima a curva prevista da curva real sem alterar, sistematicamente, o sinal da variação prevista entre dois pregões consecutivos. Trata-se de um achado metodologicamente relevante, pois indica que ganhos direcionais exigiriam formulações explicitamente orientadas à classificação do sentido do movimento, e não apenas o refinamento da regressão de preço.

5.4 Comparação entre Ativos Brasileiros e Norte-Americanos

A análise separada dos dois mercados revela diferenças estruturais atribuíveis às características dos ambientes econômicos e das dinâmicas de negociação de cada bolsa, embora o padrão qualitativo dos resultados — ganho de magnitude com o híbrido, ausência de poder direcional em ambos os modelos — se repita nos dois contextos.

Nas médias brutas, o mercado brasileiro apresentou MAPE inferior ao norte-americano tanto no LSTM (4,51% contra 7,42%) quanto no híbrido (3,26% contra 6,54%). Essa comparação, contudo, é fortemente distorcida pela NVDA: excluído esse *outlier*, o MAPE médio dos ativos norte-americanos recua para 3,29% no LSTM e 2,47% no híbrido, e o R^2 médio sobe para 0,960 e 0,975, respectivamente — desempenho superior ao dos ativos brasileiros. Esse resultado é coerente com o perfil da carteira norte-americana selecionada, composta por ações de tecnologia de altíssima liquidez e tendências mais bem definidas no período, em contraste com a maior sensibilidade dos papéis da B3.

Os casos problemáticos, por outro lado, distribuem-se de forma distinta entre os mercados. No lado norte-americano, o erro concentra-se quase integralmente na NVDA, cujo regime de preço no período de teste inviabilizou o ajuste de ambos os modelos. No lado brasileiro, a degradação é mais difusa e recai sobre dois papéis de elevada volatilidade: a MGLU3, com o maior MAPE entre os ativos de ajuste válido (18,31% no LSTM; 13,20% no híbrido), e a PETR4, com o menor R^2 do mercado brasileiro (0,547 no LSTM; 0,708 no híbrido) — comportamento compatível com as fortes oscilações e mudanças de regime que caracterizaram esses ativos na janela analisada.

Quanto à Acurácia Direcional, os dois mercados são estatisticamente equivalentes: 51,3% (EUA) contra 50,6% (Brasil) no LSTM, e 50,4% contra 49,8% no híbrido. A proximidade do patamar aleatório em ambos os contextos sugere que a dificuldade de prever a direção de movimentos diários não decorre de particularidades institucionais de cada bolsa, mas de uma característica estrutural das séries de preços em frequência diária, discutida a seguir.

5.5 Discussão dos Resultados

Os resultados obtidos corroboram *parcialmente* a hipótese central desta pesquisa. A integração entre uma arquitetura de aprendizado profundo especializada em séries temporais (LSTM) e um modelo baseado em árvores de gradiente (*Gradient Boosting*) por meio de um *Ensemble* em dois estágios produziu, de fato, previsões de magnitude consistentemente superiores às do componente neural isolado — padrão de complementaridade amplamente documentado na literatura recente sobre modelos híbridos [28, 25]. Entretanto, esse ganho não se estendeu à previsão da direção dos movimentos, dimensão em que ambos os modelos permaneceram próximos do desempenho aleatório. A discussão a seguir examina as causas e as implicações desse resultado.

O primeiro fator explicativo é o fenômeno conhecido como *lag bias*: modelos autorregressivos treinados para minimizar o erro quadrático tendem a prever, para o instante $t + 1$, um valor próximo ao observado em t , gerando uma curva prevista que “segue” a curva real com atraso de um período. Esse comportamento minimiza eficientemente o erro abso-

luto (MAE e RMSE) e produz valores elevados de R^2 , mas carrega pouca informação sobre o sentido do próximo movimento. Como o estágio de correção residual do modelo híbrido é treinado com objetivo da mesma natureza — reduzir a distância entre previsão e valor observado —, ele comprime a amplitude dos erros sem reverter o atraso estrutural da previsão. O resultado empírico é exatamente o observado: melhora de 25% no erro percentual médio, mas com estagnação na Acurácia Direcional. Esse achado possui valor metodológico próprio, pois demonstra que a otimização de métricas de regressão não constitui caminho suficiente para a obtenção da direção do ativo, e que trabalhos futuros interessados nessa dimensão devem recorrer a formulações de classificação binária (alta/baixa), funções de perda sensíveis à direção ou variáveis explicativas exógenas.

Em segundo lugar, os resultados reforçam uma ressalva importante quanto ao uso do R^2 como medida de qualidade em séries com forte autocorrelação: um modelo que simplesmente retornasse o valor do dia anterior atingiria R^2 elevado sem qualquer utilidade preditiva. Os valores de R^2 superiores a 0,95 observados em boa parte da amostra devem, portanto, ser interpretados com cautela, e é justamente a Acurácia Direcional — por ser insensível à magnitude do erro e focada exclusivamente no sentido do movimento — que oferece o retrato mais honesto da utilidade prática dos modelos. Sob essa métrica, os resultados aqui obtidos, situados na faixa de 45% a 55%, são compatíveis com a literatura, que documenta a extrema dificuldade de previsão direcional de retornos diários.

O caso da NVDA merece análise específica, por configurar falha completa de ajuste (R^2 negativo em ambos os modelos e MAPE superior a 43%). A explicação mais plausível reside na combinação entre a divisão cronológica dos dados e a normalização *Min-Max* ajustada exclusivamente sobre o conjunto de treinamento: em razão da valorização extraordinária do ativo no período mais recente da série — impulsionada pelo *boom* de demanda por semicondutores para aplicações de Inteligência Artificial —, os preços do conjunto de teste situaram-se muito acima do intervalo observado durante o treinamento, forçando o modelo a extrapolar para regiões do espaço de entrada jamais vistas e produzindo subestimação sistemática das previsões. Padrão análogo, em menor intensidade, explica os ajustes degradados de PETR4 e MGLU3, ativos que atravessaram mudanças de regime e volatilidade acentuada na janela de teste.

Do ponto de vista prático, os resultados delimitam com clareza o papel adequado da plataforma desenvolvida: as previsões geradas pelos modelos devem ser apresentadas ao usuário como estimativas de trajetória e magnitude de preço — dimensão em que o modelo híbrido demonstrou ganho real e consistente —, e não como sinais de compra ou venda, uso para o qual nenhum dos modelos avaliados apresentou poder estatístico. Essa transparência quanto aos limites dos modelos é, em si, uma contribuição relevante para o objetivo de inclusão financeira que orienta este trabalho, na medida em que evita transmitir ao investidor iniciante uma falsa sensação de previsibilidade do mercado.

Cabe, por fim, registrar o rigor metodológico que sustenta a validade dos números reportados. Todo o fluxo experimental foi conduzido de modo a impedir vazamento de informação (*data leakage*): a divisão dos dados preservou estritamente a ordem cronológica, o normalizador foi ajustado apenas sobre o conjunto de treinamento, o XGBoost foi treinado exclusivamente sobre resíduos gerados dentro desse mesmo conjunto e todas as métricas reportadas referem-se ao conjunto de teste, jamais exposto a qualquer etapa de ajuste. Resultados direcionais próximos do acaso, nessas condições, não representam falha do estudo, mas o retrato fidedigno da dificuldade do problema — e conferem credibilidade aos ganhos de magnitude efetivamente demonstrados. Vale registrar, ainda, que esse desempenho foi medido sobre um período histórico específico, e que o comportamento em condições de mercado futuras — especialmente em crises ou diante de eventos externos abruptos — pode diferir do observado.

6. CONSIDERAÇÕES FINAIS

Este trabalho teve como ponto de partida um problema concreto: a baixa inclusão financeira da população brasileira, associada à dificuldade de acesso a ferramentas avançadas de análise de investimentos, geralmente restritas a investidores institucionais e plataformas proprietárias. Diante desse contexto, foi proposto o desenvolvimento e a avaliação de um sistema híbrido para previsão de ativos financeiros, combinando uma rede Long Short-Term Memory (LSTM) com um modelo XGBoost para correção residual, integrado a uma plataforma web de código aberto destinada a facilitar o acesso de investidores às informações produzidas pelos modelos.

Ao término da pesquisa, verifica-se que o objetivo geral e os objetivos específicos foram plenamente alcançados. Realizou-se uma revisão da literatura sobre Inteligência Artificial aplicada ao mercado financeiro, coletaram-se e processaram-se séries históricas de vinte ativos pertencentes aos mercados brasileiro e norte-americano, implementaram-se e avaliaram-se os modelos preditivos sob um protocolo experimental rigoroso e desenvolveu-se uma plataforma web capaz de disponibilizar os resultados de forma intuitiva e acessível ao usuário final.

Os experimentos demonstraram que o modelo híbrido apresentou ganhos consistentes em relação ao modelo LSTM isolado na previsão da magnitude dos preços futuros. Em todos os ativos avaliados foram observadas reduções nas métricas de erro, como RMSE e MAPE, evidenciando que o estágio de correção residual desempenhou papel relevante no refinamento das previsões. Os maiores benefícios foram observados justamente em ativos de maior volatilidade, como TSLA, PETR4 e MGLU3, corroborando evidências encontradas na literatura sobre a complementaridade entre redes recorrentes e métodos de *Gradient Boosting*.

Por outro lado, a análise da acurácia direcional revelou uma limitação importante. Embora o modelo híbrido tenha reduzido significativamente os erros de regressão, sua capacidade de prever corretamente o sentido dos movimentos de mercado permaneceu próxima ao acaso, variando entre aproximadamente 45% e 55%. Esse resultado demonstra que melhorias em métricas tradicionais de regressão não necessariamente se traduzem em maior capacidade de antecipar tendências de mercado, reforçando a complexidade inerente à previsão de séries financeiras diárias e a importância de protocolos experimentais livres de vazamento de dados.

As contribuições desta pesquisa podem ser observadas em três perspectivas complementares. No âmbito científico, o trabalho apresenta uma comparação sistemática entre ativos brasileiros e norte-americanos sob um mesmo critério experimental, permitindo avaliar o comportamento do modelo híbrido em diferentes mercados. Sob o aspecto metodológico, evidencia tanto o potencial quanto as limitações da correção residual com XGBoost,

além de discutir aspectos relevantes relacionados ao pré-processamento das séries temporais e aos riscos da interpretação isolada de métricas estatísticas em problemas de previsão financeira. Sob a perspectiva prática, entrega uma plataforma web de código aberto que aproxima técnicas avançadas de Inteligência Artificial do investidor comum, apresentando previsões acompanhadas de indicadores de desempenho e de suas limitações. Como forma de reforçar a transparência e a reprodutibilidade científica, todo o código-fonte desenvolvido, incluindo o pipeline de coleta e processamento dos dados, o treinamento dos modelos e a aplicação web, foi disponibilizado em um repositório público no GitHub¹, permitindo que outros pesquisadores reproduzam, validem e estendam os experimentos apresentados neste trabalho.

Em síntese, esta pesquisa demonstra que a Inteligência Artificial pode contribuir significativamente para o desenvolvimento de ferramentas capazes de apoiar investidores e ampliar o acesso à informação financeira de qualidade. Embora o modelo híbrido LSTM-XGBoost tenha apresentado ganhos expressivos na redução dos erros de previsão, os resultados também evidenciam os limites atuais da previsão direcional de ativos financeiros em frequência diária. Dessa forma, a principal contribuição deste trabalho não reside apenas na proposição de um modelo preditivo mais preciso, mas na construção de uma solução tecnicamente consistente, metodologicamente transparente e orientada à democratização do acesso à tecnologia aplicada ao mercado financeiro.

¹Disponível em: <https://github.com/matheusmopucrs/TCC-Pronto>.

REFERÊNCIAS BIBLIOGRÁFICAS

- [1] AMORIM, C. E. “Revisão sistemática de métodos de inteligência artificial para previsão de preços no mercado financeiro brasileiro”, Dissertação de Mestrado, Universidade de São Paulo, São Paulo, SP, Brasil, 2023.
- [2] ASSIS, L. M.; SILVA, F. A. “Inteligência artificial: aplicações e desafios no contexto brasileiro”, *Revista Brasileira de Inovação Tecnológica*, 2021, acesso em: 6 set. 2025.
- [3] B3. “Inteligência artificial e o futuro dos investimentos”. Acesso em: 1 set. 2025, Disponível em: <https://clientes.b3.com.br/w/inteligencia-artificial-e-o-futuro-dos-investimentos>, 2025.
- [4] Box, G. E. P.; Jenkins, G. M. “Time series analysis: Forecasting and control”, *Holden-Day*, 1970.
- [5] Breiman, L. “Random forests”, *Machine Learning*, vol. 45–1, 2001, pp. 5–32.
- [6] CHEN, K.; ZHOU, Y.; JIN, F. “Stock market prediction using lstm recurrent neural network”. In: *Proceedings of the 2015 IEEE International Conference on Data Science and Advanced Analytics*, 2015, pp. 1–6.
- [7] Cho, K.; van Merriënboer, B.; Gulcehre, C.; Bahdanau, D.; Bougares, F.; Schwenk, H.; Bengio, Y. “Learning phrase representations using rnn encoder-decoder for statistical machine translation”. In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734.
- [8] de Valores Mobiliários, C. “Raio x do investidor brasileiro”. Disponível em: <https://www.gov.br/cvm>, 2024.
- [9] FEBRABAN. “Maioria dos brasileiros admite entender pouco de educação financeira, mostra pesquisa”. Acesso em: 1 set. 2025, Disponível em: <https://portal.febraban.org.br/noticia/4324/pt-br/>, 2025.
- [10] FINTECHLAB. “Report fintechlab 2017: Panorama das fintechs no brasil”, Relatório Técnico, FintechLab, São Paulo, SP, Brasil, 2017, acesso em: 1 set. 2025.
- [11] FISCHER, T.; KRAUSS, C. “Deep learning with long short-term memory networks for financial market predictions”, *Journal of Financial Economics*, vol. 130–2, 2018, pp. 381–398.
- [12] GITMAN, L. J. “Princípios de Administração Financeira”. São Paulo, Brasil: Pearson, 2010, 12 ed..

- [13] GOV.BR. “Tecnologia e finanças digitais: uma revolução em movimento”. Acesso em: 6 set. 2025, Disponível em: <https://www.gov.br/investidor/pt-br/penso-logo-invisto/tecnologia-e-financas-digitais-uma-revolucao-em-movimento>, 2025.
- [14] Kim, T.; Kim, H. Y. “Forecasting stock prices with a feature fusion lstm-cnn model using different representations of the same data”, *PLOS ONE*, vol. 14–2, 2020, pp. e0212320.
- [15] Kingma, D. P.; Ba, J. “Adam: A method for stochastic optimization”, *International Conference on Learning Representations (ICLR)*, 2015.
- [16] MACHADO, J. S.; HOLANDA, F. S. R. e. a. “A inovação tecnológica e os desafios representados pela inteligência artificial”, *Revista Thema*, vol. 21–3, 2023.
- [17] MARTINS, P. “Brasil deve ter 120 milhões de investidores em criptomoedas até 2030”. Acesso em: 1 set. 2025, Disponível em: <https://www.trendsce.com.br/2025/02/11/brasil-deve-ter-120-milhoes-de-investidores-em-criptomoedas-ate-2030>, 2025.
- [18] MATSUMOTO, R. Y. “Previsão de séries temporais financeiras utilizando redes neurais recorrentes lstm: um estudo aplicado ao mercado brasileiro”, Dissertação de Mestrado, Universidade Federal do Rio de Janeiro, Rio de Janeiro, RJ, Brasil, 2019.
- [19] OLIVEIRA, M. A. “Inteligência Artificial no Sistema Financeiro Brasileiro: Transformação Digital e Inovação”. São Paulo, Brasil: Atlas, 2023.
- [20] ORSSATTO, A. L. “Estratégias híbridas de deep learning para previsão de preços de ações na b3: uma análise comparativa de modelos”, Dissertação de Mestrado, Pontifícia Universidade Católica do Rio Grande do Sul, Porto Alegre, RS, Brasil, 2025, trabalho de Conclusão de Curso em andamento.
- [21] RAIHER, A. P.; LIMA, J. F. d. “Desenvolvimento humano nas regiões brasileiras: o que fazer?”, *Revista Espacios*, vol. 38–51, 2017, acesso em: 8 set. 2025.
- [22] RUSSELL, S.; NORVIG, P. “Artificial Intelligence: A Modern Approach”. New Jersey, USA: Pearson, 2021, 4 ed..
- [23] Sharpe, W. F. “The sharpe ratio”, *The Journal of Portfolio Management*, vol. 21–1, 1994, pp. 49–58.
- [24] Tashiro, D.; Shibata, R.; Tanaka, T.; Ogawa, T. “Encoding of high-frequency order information and prediction of short-term stock price by deep learning”, *Quantitative Finance*, vol. 21–8, 2021, pp. 1351–1366.
- [25] TIAN, Y.; LI, Q.; WANG, J.; ZHANG, M. “Bayesian-optimized hybrid lstm-xgboost model for global stock market prediction”, *International Journal of Forecasting*, vol. 40–2, 2024, pp. 567–582.

- [26] UTFPR. “Gestão financeira: análise de indicadores econômico-financeiros para tomada de decisão”, Relatório Técnico, Universidade Tecnológica Federal do Paraná, Curitiba, PR, Brasil, 2025, acesso em: 1 set. 2025.
- [27] Wang, J. “The math behind lstm”. Disponível em: <https://towardsdatascience.com/the-math-behind-lstm-9069b835289d/>, 2018.
- [28] ZHU, X.; ZHANG, W.; LI, C.; WANG, H. “A hybrid lstm-xgboost model for stock price prediction with feature selection”, *Expert Systems with Applications*, vol. 195, 2022, pp. 116543.